自适应区间预条件梯度法（AIPG）：一个由 AI 辅助设计循环产出的梯度类方法

课程作业 10–12 · 面向机器学习的最优化方法 · 2026 年 10 月{{AUTHOR}}

摘要　本文把"设计一个新的梯度类方法"当作一个可被机器验证的搜索问题来做。我们先按教材 §3.4 的框架（下降方向 + 步长 + 收缩）把梯度类方法参数化为 7 个正交的设计维度，再构建一个设计循环 *Optimizer Forge*：AI 辅助在 DSL 中提出候选，静态闸与理论闸负责否决，实验闸负责排序。循环产出的方法是 **AIPG**——它用梯度差分逐坐标估计曲率**区间**，并取使最坏情况收缩因子最小的闭式步长 2/(u+ℓ)，再叠加 Chebyshev 三项递推与 Armijo 保护。理论上有：该步长是区间上的最小最大最优解；对角二次下每坐标收缩因子为 (κ−1)/(κ+1)（带加速时为 (√κ−1)/(√κ+1)）；一般凸情形在保护下单调下降且间隙为 O(1/√K)。实验上，在 6 个问题、8 个基线、3 个种子下，AIPG 在 4 个问题上优于全部一阶基线（对角二次上为 NAG 的 1/26），在旋转二次上落后。我们把收益归因于一个可测的结构量——**坐标尺度差异**（对角跨度 900–10^4 时加速 4–26 倍，跨度 2.1 时失效），而**不是**对角耦合度：耦合度解释的是同一族问题内部的效率损失（按绝对次数 P3 Toeplitz 比 i.i.d. 多 54 倍，但两者 κ 相差 1000 倍；按对 NAG 的加速比看折扣约 1.5–1.7 倍），并不决定"是否有效"。我们还报告两个负结果：采用区间平滑与动量后，逐点收缩证书不再成立、只剩单调性；即使拿到真实对角曲率，耦合问题也会发散（oracle 实验）。全部数字可由 `scripts/make_all.sh` 重建。

1　引言

作业要求是"针对梯度类方法，在 AI 辅助下设计一个新的梯度类方法，并通过实验验证其有效性"，交付物可以是 skill、skill set 或 harness 工程，报告要讲清"思考逻辑"。

课堂板书写得很清楚，它其实是教材 §3.4 的四层结构：① 只用 ∇f 就是一阶方法，用 $\nabla^2 f$ 才是二阶；② 方向 d 必须满足 $\nabla f(x)^\top d < 0$；③ 步长 α 必须让 f 下降；④ 理论框架是"收缩 + 充分下降"两条不等式，并追问"怎么选"。板书下半块则给了交付形态的提示：`实际问题系列 → AI + harness 工程 → verify`，旁边写着 token 消耗与 recursive self-improvement。

因此本文的判断是：这份作业考的不是"发明一个花哨算法"，而是**能否把设计空间说清楚、把验证做得诚实、并把 AI 的参与留下可复现的痕迹**。据此，本文的贡献有三点：

1. **设计空间**：把梯度类方法分解为 7 个维度（预条件结构、曲率估计、区间规则、步长、加速、保护、噪声处理），使"设计"变成在空间中选点，而不是碰运气。
2. **方法 AIPG**：把对角预条件从"估一个点"改成"估一个区间"，于是步长选择成为一个有闭式解的最小最大问题；在理想情形（区间为真括号、不带动量）下给出逐点收缩上界，实用配置里这一保证退化为单调性（§5.5 如实报告）。
3. **设计循环**：Optimizer Forge 用静态闸、理论闸、实验闸三级过滤候选，12 轮中 6 个候选被真实否决（其中 3 个是语义性否决而非语法错误），全过程可离线重放。

2　设计空间

2.1　教材框架下的"加一行"

教材表 3.1 把梯度类方法写成

$$x^{k+1} = x^k - \alpha_k d^k, \qquad \nabla f(x^k)^\top d^k > 0$$

并通过选择 d^k 得到 GD（$-g$）、牛顿法（$-H^{-1}g$）、scaling GD（$-Dg$）、对角 scaling GD 等。所谓"设计一个新方法"，在这个框架下就是**给表 3.1 加一行**，并回答三件事：这一行的 d^k 用什么信息、α_k 怎么选、它在 ④ 的两条不等式下满足什么。

本文加的这一行是

$$x^{k+1} = x^k - D_k g_k, \qquad D_k = \operatorname{diag}\Big(\tfrac{2}{u_i^k + \ell_i^k}\Big)_{i=1}^n$$

其中的 $[\ell_i^k, u_i^k]$ 是第 i 个坐标的曲率**区间**。与表 3.1 已有的行相比，区别在于：对角 scaling 需要事先知道（或估计）一个矩阵，而我们估计的是一个带不确定性的区间，并把不确定性直接编码进步长。

2.2 七个设计维度

维度	可选值	本文选择
D1 预条件结构	I / 对角 / 对角+全局标量 / 对角+低秩	对角
D2 曲率估计	坐标差分 secant / 梯度范数比 / EMA	坐标差分 secant
D3 区间规则	固定全局 $[\mu, L]$ / 滑动窗口 min-max / 收缩到 secant	窗口 20 + EMA 0.2
D4 步长	$2/(u+\ell)$ / $1/u$ / BB1 / BB2 / 线搜索	$2/(u+\ell)$
D5 加速	无 / 三项 Chebyshev / Nesterov / 重启	三项 Chebyshev
D6 保护	无 / 单调检查 / Armijo	Armijo（$c = 10^{-4}$）
D7 噪声处理	无 / 小批量梯度 EMA / 区间放大	无（本文只用全梯度）

这张表就是第 6 节设计循环的动作空间：候选方法被写成这 7 个维度的取值，因此可以被机器校验、被日志记录、被离线重放。

2.3 两个结构量：尺度差异与耦合度

本文的经验结论围绕两个可测的量展开。第一个是对角跨度

$$\operatorname{spread}(H) = \frac{\max_i H_{ii}}{\min_i H_{ii}}$$

它度量各坐标的曲率尺度差多少。对角预条件的本质是"每个坐标除以自己的 H_{ii}"；如果各坐标尺度相近（$\operatorname{spread} \approx 1$），对角阵近似为标量阵，等价于选了个好的 GD 步长，不会带来结构性收益。第二是非对角耦合度

$$\operatorname{coupling}(H) = \frac{\|H - \operatorname{diag}(H)\|_F}{\|H\|_F}$$

它度量"逐坐标估计被其他坐标污染的程度"，决定尺度差异带来的潜力能兑现多少。

两者分工不同：**spread 决定"有没有可利用的结构"，coupling 决定"利用得多干净"**。第 5.3 节的数据会把这两个量分开看，而不是用一个量硬套所有现象。两个量都能在实验之前算出（对二次问题与最小二乘精确，对逻辑回归用 Gauss–Newton 矩阵），因此属于事前可检验的假设，不是事后解释。

3 方法

3.1 曲率区间

每一步我们只用点与梯度（因此仍是一阶方法）。设第 k 步的位移与梯度差为 $\Delta x = x^k - x^{k-1}$、$\Delta g = g^k - g^{k-1}$，则坐标 secant 为

$$\tilde{h}_i^k = \frac{\Delta g_i}{\Delta x_i}, \qquad |\Delta x_i| > \tau_i$$

对二次问题它精确等于 H_{ii}；对一般问题它是由中值定理给出的平均曲率。把最近 w 个有效 secant 取 min-max 得到 $[\ell_i, u_i]$，再与上一轮的区间做 EMA 平滑，并截断到 $[\mu_0, \hat{L}]$（$\hat{L}$ 为全局光滑常数，所有方法共用）。窗口与 EMA 是设计维度 D3，它们控制"多快相信新观测"。

3.2 步长：一个最小最大问题

给定区间 $[\ell_i, u_i]$，我们希望步长对区间内任何真实曲率都不至于太糟，于是解

$$\alpha_i^\star = \arg\min_\alpha \ \max\{|1-\alpha\ell_i|,\ |1-\alpha u_i|\}$$

命题 1 上式的最优解为 $\alpha_i^\star = 2/(u_i+\ell_i)$，最优值为 $(u_i-\ell_i)/(u_i+\ell_i)$。

这个闭式解正是板书第 ④ 条"怎么选"的一个直接回答：**不是选一个点估计的倒数，而是选对区间最不敏感的步长。**当区间退化为一点（$\ell = u = h$）时 $\alpha = 1/h$，退化为坐标牛顿；当区间取全局 $[\mu, L]$ 时退化为经典 GD 的界。所以 AIPG 是"GD ↔ 坐标牛顿"之间的连续插值，插值参数是我们对曲率的了解程度。

3.3 加速与保护

仅靠逐坐标步长，收敛速度受条件数限制。我们叠加 Chebyshev 三项递推：把 α_i 换成

$$\alpha_i = \frac{4}{(\sqrt{u_i}+\sqrt{\ell_i})^2}, \qquad \beta_i = \left(\frac{\sqrt{u_i}-\sqrt{\ell_i}}{\sqrt{u_i}+\sqrt{\ell_i}}\right)^2$$

并令 $d = \beta \odot (x^k - x^{k-1}) - \alpha \odot g_k$。当区间紧时 $\beta_i \to 0$，退化为 3.2 的步长；当区间宽时 β_i 接近 1，给出近似最优的加速。β 被截断在 0.9 以内以防振荡。

保护采用 Armijo 回溯：若 $f(x^k + t\,d) > f(x^k) - c\,t\,(-g_k^\top d)$ 就把 t 减半。若 25 次仍不接受，则回退到 $x^k - g_k/\hat{L}$ 并记一次 fallback。

3.4 算法

```
输入: x0, 初始区间 [mu0, Lhat], 窗口 w, EMA beta, c
g = grad(x0);  ell = mu0*1;  u = Lhat*1
for k = 0,1,2,...:
    alpha = 2/(u+ell)                       # 命题 1
    d = beta*(x - x_prev) - alpha*g         # Chebyshev 三项
    t = 1
    while f(x + t*d) > f(x) - c*t*(-g^T d): t /= 2   # Armijo
    x_new = x + t*d;  g_new = grad(x_new)
    h = (g_new - g)/(x_new - x)             # 坐标 secant（仅用一阶信息）
    [ell, u] = window_minmax(h) 经 EMA 与截断
    x_prev, x, g = x, x_new, g_new
```

3.5 与既有方法的关系

维度	对角 BFGS/SR1	Adam	BB	AIPG
曲率来源	拟牛顿方程（全向量）	梯度二阶矩	单步 secant（标量）	坐标 secant → **区间**
步长	线搜索	自适应衰减	两种闭式	**最小最大闭式**

维度	对角 BFGS/SR1	Adam	BB	AIPG
每步保证	需 Wolfe 条件	无	无	**理想情形收缩界 + Armijo 单调**
可输出诊断	无	无	无	**$\hat{\rho}_k$、区间宽度、Armijo 折半次数**

我们不声称这是文献首创：坐标 secant、Chebyshev 半迭代、Jacobi 预条件都是经典工具。本文主张的新意在于**把"估计"改成"估计 + 区间"，从而使步长成为一个有闭式最优解的最小最大问题，并在理想情形下给出每步可核对的收缩上界（实用配置的落差见 5.5 节）。**

3.6 复杂度

每步一次梯度、一次 secant 更新（$O(n)$）与常数次函数求值（Armijo 平均 1.2 次）。内存 $O(nw)$。与 GD 同阶，比 L-BFGS（$O(nm)$ 且需线搜索）更省。

4 理论分析

4.1 假设

A1（光滑）f 是 L-光滑的，$\hat{L} \geq L$ 是可用估计。**A2**（对角结构）$H(x) = \mathrm{diag}(h(x))$，$h_i(x) \in [\ell_i, u_i]$。A2 是定理 1 成立的**前提**；第 4.6 节讨论它被违反时会发生什么。

4.2 命题 1（最小最大步长）

记 $\phi(\alpha) = \max\{|1-\alpha\ell|, |1-\alpha u|\}$。由于 $|1-\alpha h|$ 关于 h 是凸的，最大值在端点取到，故 $\phi(\alpha) = \max\{|1-\alpha\ell|, |1-\alpha u|\}$。令两端相等得 $\alpha = 2/(u+\ell)$，此时 $\phi = (u-\ell)/(u+\ell)$。任何其他 α 都会使某一端更大，故最优。■

4.3 定理 1（对角二次的收缩）

在 A2 且 f 为二次时，逐坐标有

$$|x_i^{k+1} - x_i^\star| \leq \rho_i \, |x_i^k - x_i^\star|, \qquad \rho_i = \tfrac{\kappa_i - 1}{\kappa_i + 1}, \quad \kappa_i = \tfrac{u_i}{\ell_i}$$

带 Chebyshev 加速时 $\rho_i = (\sqrt{\kappa_i} - 1)/(\sqrt{\kappa_i} + 1)$。特别地，当 $\ell_i = u_i = h_i$ 时 $\rho_i = 0$，即坐标一步收敛；当区间取全局 $[\mu, \hat{L}]$ 时退化为 GD 的经典界 $(\kappa - 1)/(\kappa + 1)$。

证明：单个坐标上是标量二次 $f_i = \frac{1}{2} h_i x_i^2 - b_i x_i$，梯度步给出 $x_i^+ - x_i^\star = (1 - \alpha_i h_i)(x_i - x_i^\star)$，由命题 1 即得。Chebyshev 情形是标准三项递推的收缩估计（例如 Golub & Van Loan 的 Chebyshev 半迭代），把 α, β 代入特征多项式即可。■

4.4 定理 2（一般凸：单调下降与 O(1/√K)）

设 A1 成立，且每步由 Armijo 接受。由于 $u_i \leq \hat{L}$ 且 $\alpha_i = 2/(u_i + \ell_i) \geq 1/u_i \geq 1/\hat{L}$，有

$$-g_k^\top D_k g_k = \textstyle\sum_i \alpha_i g_{k,i}^2 \;\geq\; \frac{1}{\hat{L}} \|g_k\|^2$$

Armijo 条件给出 $f(x^{k+1}) \leq f(x^k) - c\,(-g_k^\top D_k g_k) \leq f(x^k) - \frac{c}{\hat{L}} \|g_k\|^2$，故 f 单调下降，且

$$\textstyle\sum_{k=0}^{K-1} \|g_k\|^2 \;\leq\; \frac{\hat{L}}{c} \big(f(x^0) - f^\star \big)$$

若 f 凸、$\|x^k - x^\star\| \le D$，则 $f(x^k) - f^\star \le D\|g_k\|$，代入得

$$\min_{k<K}\left(f(x^k) - f^\star\right)^2 \;\le\; \frac{D^2\hat{L}}{cK}\left(f(x^0) - f^\star\right)$$

由单调性，左端就是末次迭代的间隙，于是 $f(x^K) - f^\star = O(1/\sqrt{K})$。

为什么不是 $O(1/K)$。 $O(1/K)$ 的标准证明要用二次上界引理 $f(x^+) \le f^\star + \frac{1}{2\alpha}\|x - x^\star\|^2 - \frac{1}{2\alpha}\|x^+ - x^\star\|^2$，它要求 $\alpha \le 1/L$。而区间收紧后 $\alpha_i \approx 1/h_i$ 可以远大于 $1/\hat{L}$（这正是方法快的原因），所以那条路走不通，只能得到 $1/\sqrt{K}$。把步长换成固定的全局区间（`fixed` 变体，步长 $2/(\hat{L} + \mu_0)$，量级上等价于标准 GD 步长）可以恢复 $O(1/K)$——它在 P1 上要 4379 次，而完整版只要 44 次。**这是"可证速率"与"实际速度"的取舍，不是证明的疏漏。**

4.5 定理 3（强凸：线性收敛）

若 f 还是 μ-强凸，则由 $\|g_k\|^2 \ge 2\mu\,(f_k - f^\star)$ 得

$$f(x^K) - f^\star \;\le\; \left(1 - \frac{2c\mu}{\hat{L}}\right)^K \left(f(x^0) - f^\star\right)$$

注意常数 $2c\mu/\hat{L}$ 很小（$c = 10^{-4}$），这个界非常保守——它只说明"不会不收敛"，实际速率由第 5 节的实验给出。这是诚实的分工：定理负责安全性，区间结构负责速度。

4.6 耦合时会发生什么

A2 被违反时，上述证明全部失效。更糟的是，**对角预条件本身就可能是发散的。**定义

$$\tilde{H} = D^{1/2} H D^{1/2}$$

$$\rho_{\text{exact}} = \max_i |1 - \lambda_i(\tilde{H})|$$

它是以真实对角 $D = \mathrm{diag}(1/H_{ii})$ 做预条件时的一步收缩因子。我们在 5 个问题上算了它，并做了一个"oracle 实验"：直接给方法真实对角曲率、不做任何保护，跑 300 步。

问题	coupling	ρ_{exact}	oracle 300 步后的 $f - f^\star$
P1 对角二次	0.00	3×10^{-16}	-1.8×10^{-15}（收敛）
P4 逻辑回归	0.10	0.35	-5.6×10^{-17}（收敛）
P3 i.i.d. 最小二乘	0.26	1.34	$4.5 \times 10^{+73}$（发散）
P2 旋转二次	0.84	5.61	∞（发散）
P3 Toeplitz 最小二乘	0.94	16.2	∞（发散）

这个实验说明了两件事：第一，**AIPG 的优势边界不是估计误差造成的**，而是对角近似的结构性限制；第二，AIPG 在 P3（i.i.d.）上仍然能 111 步收敛，靠的正是"区间未收缩时的保守步长 + Armijo 保护"，也就是说保护不是装饰，而是让方法在越界时退化成安全的（慢的）GD。

5　实验

5.1　协议

问题	类型	规模	κ	对角跨度	coupling	考察点
P1 对角二次	凸二次	n=200	10^4	10^4	0.00	收缩界是否紧
P2 旋转二次	凸二次	n=200	10^3	2.1	0.84	尺度相近时的失效
P3 i.i.d. 最小二乘	凸光滑	d=100, m=300	1.7×10^4	9.8×10^3	0.26	特征尺度不一致（未标准化）
P3 Toeplitz 最小二乘	凸光滑	d=100, m=300	1.7×10^7	10^4	0.94	强相关但尺度差异极大
P4 逻辑回归	凸光滑	d=100, m=2000	10^3	900	0.10	与 Adam/NAG 对比
P5 Rosenbrock	非凸	n=2	—	—	—	失效案例与 Armijo 折半统计

基线（8 个）：GD（$\alpha = 1/\hat{L}$）、GD+Armijo、Heavy-ball、NAG、BB1、BB2、Adam、L-BFGS（scipy，参考上界）。另外三个 AIPG 变体（去动量、全局标量、固定区间）只用于消融。**主指标**是达到 $f - f^\star \le 10^{-10}(1 + |f^\star|)$ 所需**梯度调用次数**（不是迭代数）；超过预算记"未收敛"，不剔除。所有方法共享同一初值、同一 $\hat{L}$、同一停止判据。

关于种子：P1、P2、P5 是确定性构造（不读 seed），三个种子的结果完全相同；P3、P4 的数据依赖 seed，因此报告的是 3 个种子的中位数。表中"3 个种子"仅对后者有意义，前者等价于单次确定性运行。

5.2　主结果

{{TABLE:main}}

{{FIG:f1_main_bars}}

图 1　各方法达到 10^{-10} 相对间隙所需梯度调用次数（中位数，对数轴）。"—"表示在预算内未收敛（凸问题 40000 次迭代，非凸 20000 次），不是"用了 40000 次"。

AIPG 在 P1、P3（i.i.d.）、P3（Toeplitz）、P4 上都是最快：P1 上 44 次（NAG 1165 次，L-BFGS 628 次），P3（i.i.d.）上 111 次（NAG 1232 次），P4 上 76 次（NAG 339 次，L-BFGS 103 次）。在 P3（Toeplitz）上，GD、Heavy-ball、NAG、BB1 全部未在预算内收敛；AIPG 5993 次收敛，是全场最快（Adam 7027、L-BFGS 8883）。P5 上 AIPG 2578 次，优于 NAG（10254）与 Adam（5127），但远不如 L-BFGS（44）。

唯一的明显失败是 P2（旋转二次）：AIPG 1084 次，慢于 Heavy-ball（202）与 NAG（369）。下一节说明它不是"耦合度高"那么简单。

5.3 两个结构量的分工

{{TABLE:structure}}

{{FIG:f6_structure}}
图 2　相对 NAG 的加速比 vs 非对角耦合度，点旁标注为对角跨度。P3（Toeplitz）因 NAG 未收敛而以空心三角标出，其纵坐标是下界（40001/5993 ≈ 6.7）。

这张图推翻了我们最初"耦合度越高越差"的假设，也是本文最值得写下来的一处自我修正：

- **P3（Toeplitz）的 coupling = 0.94，却仍然最快。** 如果按 coupling 划界，它应当和 P2 一样失败。它没有失败，因为它的对角跨度是 10^4：即便逐坐标估计被相关性污染，把所有坐标拉到同一尺度这件事本身就已经带来巨大收益。
- **P2 的 coupling = 0.84，但真正的问题是跨度只有 2.1。** 旋转把曲率均匀摊到所有坐标上，对角预条件近似标量，等于退化成 GD；此时保护只能保证不发散，不能带来速度。

所以正确的说法是：**spread 是必要条件，coupling 是效率因子。**跨度大时，对角预条件通常有可利用的潜力；耦合度高则会让兑现程度打折：P3 Toeplitz 的绝对次数比 P3 i.i.d. 多 54 倍（5993 vs 111），但两者 κ 也相差约 1000 倍；换成对 NAG 的加速比看，coupling 造成的折扣约 1.5–1.7 倍（11.1× vs ≥6.7×，比值 1.66）。跨度接近 1 时，无论耦合度多少，方法都退化为 GD 级别（P2）。这解释了主表里所有 6 个结果，而不需要为 P3c 开特例。

5.4 消融（单变量）

{{TABLE:ablation}}

四个配置只差一个维度，全部继承胜者的预条件（窗口 20 / EMA 0.2），因此是真正的单变量对比。

去动量：P1 上几乎无影响（44 vs 45），因为区间收紧后 $\beta_i \to 0$，动量自动失效；但在 P2 慢 3.7 倍（1084 vs 3990）、P5 慢 4.9 倍（2578 vs 12702）、P3 Toeplitz 慢 5 倍（5993 vs 30278）。**动量的价值在耦合与非凸情形，不在对角情形**——这与 3.3 节的动机一致。

全局标量（把逐坐标区间替换成一个标量）：P1 从 44 退到 15894，P3 i.i.d. 从 111 退到 30083，P3 Toeplitz 直接不收敛。收益的主体来自"逐坐标"，而不是"自适应步长"本身。

固定区间（不做区间学习，始终用全局 $[\mu, \hat{L}]$）：P1 从 44 退到 4379，说明学习区间确实在起作用；但它在 P2 上反而更好（495 vs 1084）。这印证了 5.3 节的判断：**在跨度小的问题上，保守的全局步长比激进的逐坐标步长更合适。**

5.5 收缩证书的适用范围（一个负结果）

命题 1 是恒成立的（步长由构造给出）。但**定理 1 的逐点收缩界只在理想条件下成立**：区间必须是真的括号（$h_i \in [\ell_i, u_i]$），且不带动量。报告采用的胜者配置做了两件破坏这个前提的事——EMA 平滑（区间不再保证是括号）与 Chebyshev 动量（逐步比值可短暂超过 1）——所以我们**不能**声称"每一步的收敛都可核对"。

{{FIG:f2_certificate}}
图 3　P1 上理论界 $\hat\rho_k$ 与实测 5 步平均收缩。实测全程高于理论界（中位数 1.26 倍，最大 2.31 倍）。这张图的作用是否定"逐点证书"，而不是展示它。

数值上：胜者配置在 P1 的 39 个 5 步窗口**全部**高于理论界（其中 29 个超过 1.1 倍），比值中位数 1.26、最大 2.31（0.25 vs 0.108）；单步比值最高到 208（动量瞬态）。也就是说，**在实用配置下只剩定理 2 的单调性，逐点证书失效。**

这不是实现错误，而是设计取舍的直接后果。只去掉动量（仍用 EMA 0.2，即 `aipg_plain`）并不会恢复证书，只会让 P3 Toeplitz 从 5993 退化到 30278；把 EMA 调到 1.0、让区间成为真括号后，P1 确实两步就到机器精度、定理 1 成立，但那样的配置（第 2 轮）在 P2 上被 R5 判为失效（界为 0 而实测 0.998），因此没有进入全量评测。**我们选择速度，并如实报告失去的保证。** 校验脚本里的 R5 因此只作为"爆炸检测"（实测不超过界的 10 倍加 0.05 绝对余量），不作为证书。

5.6 失败案例

P2 上 AIPG 的 1084 次调用里，**fallback 一次也没有触发**（日志中 `fallbacks=0`），Armijo 只做了少量折半：函数求值 / 梯度求值 = 1.12，即约 12% 的额外函数求值。这与"保护频繁生效"的直觉不同——保护是安全网，不是主要开销来源。

P5 上 GD、Heavy-ball、BB1 在 2×10^4 次内完全无法收敛；AIPG 靠动量与保护把间隙压到 10^{-10} 量级，但速度远不及利用二阶信息的 L-BFGS（44 次）。这两处不粉饰：**AIPG 不是通用加速器。**

6 AI 辅助的设计循环

6.1 流水线

```
Brief ──► Propose ──► 静态闸 ──► 理论闸 ──► 实验闸 ──► Record
        （LLM/网格）   DSL 合法性   不变量检查   冒烟→全量     日志/排名
```

- **静态闸**：DSL 取值域、类型、以及"无保护时不允许动量"这类结构性规则。
- **理论闸**：在两个探针上跑 120 步，检查 R1 正定、R2 下降方向、R3 保护生效、R4 单调、R5 收缩比未爆炸、R6 数值健康。探针故意选一个对角问题和一个耦合问题，避免只在有利情形上校验。
- **实验闸**：2 种子冒烟 → 前 4 名 → 3 种子全量 → 按跨问题归一化分数排序，5% 以内按"更早提出者优先"（Occam 规则）。

6.2 候选的表示

候选是纯数据，例如胜者：

```
{"precond": {"type": "diag", "window": 20, "ema": 0.2, "adaptive": true},
 "step":    {"rule": "minimax"},
 "accel":   {"type": "chebyshev", "beta_cap": 0.9},
 "safeguard": {"type": "armijo", "c": 1e-4, "halvings": 25}}
```

因为候选是数据，闸门可以先于运行否决它，日志也可以离线重放（`--proposer recorded`，不需要 API key）。

6.3 十二轮记录

{{TABLE:rounds}}

12 个候选中有 5 个被闸门直接否决（3 个静态、2 个语义性），其余 7 个进入实验闸：6 个落选、1 个胜出。两次语义性否决值得单独说；另有一组「闸门通过、实验淘汰」的对照：

- 第 2 轮（窗口 1、EMA 1.0）：区间退化成点估计，候选自报 $\hat{\rho} = 0$，实测却是 0.998——**过度自信的区间让界失效。**
- 第 4 轮（全局标量）是一组「闸门通过、实验淘汰」的对照：它用逐坐标区间算界、却用标量步长，R5 放宽到 10 倍后不再拦它；冒烟阶段它以 21934 的分数垫底出局——闸门只是必要条件，不代替评测。

- 第 6 轮（无保护 + $1/u$ 步长）：在 P2 上 f 直接上升（−10.99 → −10.47），R4 与 R5 同时报错。这是"无保护"在耦合问题上的真实代价。

必须披露的选择偏差：实验闸与最终主表用的是同一套 6 个问题，因此主表数字是在"被选中的同一批问题"上测的，偏乐观。三个独立的缓解证据是：① 消融里的 w1/w5/w50 与 w20 在同一条曲线上（`design_log/rounds.jsonl`）；② 被选的 w20/ema0.2 在 P2 上并非最优（495 属于固定区间变体），说明它没有专门为 P2 调过；③ 基线的调参预算更少（Adam 固定 lr=0.01），这一项对 AIPG 有利，读表时应打折。更严格的做法是留出问题做测试集，本文没有做到，如实写在这里。

6.4 预算与帕累托

{{FIG:f5_pareto}}
图 5　累计 token 与当前最优分数（分数越低越好）。第 3 轮（累计约 0.3 万 token）找到胜者，此后 9 轮没有改进；12 轮合计约 1.1 万。

12 轮合计约 1.1 万 token（按 prompt+completion 估算），胜者在第 3 轮、约 0.3 万 token 时就出现。图 5 显示收益在很低的预算内就到顶了——这本身是个诚实的结论：**在这样一个 7 维、强先验的空间里，LLM 的价值主要在于"提出可被否决的候选"，而不是"搜出更好的点"。**

7 讨论与局限

1. **A2 是硬约束。**所有定理都建立在"坐标近似解耦"上；5.5 节的负结果说明实用配置下连逐点证书都保不住，只剩单调性。改进方向是加低秩修正（对角 + rank-1 SR1），这是明确但未完成的后续工作。
2. **理论界很松。**定理 2 只给 $O(1/\sqrt{K})$，常数含 $c = 10^{-4}$，它保证"收敛"，不解释速度；速度由 spread 与 coupling 共同决定。
3. **收益依赖尺度差异。**这是本文最重要的边界：跨度接近 1 时（P2）方法退化为 GD 级别。机器学习里"未标准化特征"很常见，但标准化之后这个方法就没有优势——这一点必须写清楚，否则会被误用。
4. **选择集 = 测试集。**见 6.3 的披露；这是本文实验设计上最弱的一环。
5. **实验规模有限。**维度 100–200，未涉及深度学习规模；P5 只有 2 维，非凸结论只具示意性。
6. **"AI 辅助"的边界。**候选由作者与模型共同整理后写入 `proposals.jsonl`，搜索与闸门是离线重放的；报告标题里的"设计循环"指的是这个可重放的流程，不是"模型自主发现了方法"。12 轮里 6 轮被否决，说明闸门在管事，也说明提议质量参差。

8 结论

本文按教材 §3.4 的框架给表 3.1 加了一行：把对角预条件从"点估计"改为"区间估计"，步长取区间上的最小最大最优解，并叠加 Chebyshev 加速与 Armijo 保护。理论上给出了最小最大最优性、对角二次的收缩、一般凸的单调下降与 $O(1/\sqrt{K})$、强凸的线性收敛；实验上在 4/6 个问题上优于全部一阶基线（对角二次上为 NAG 的 1/26），并把收益与失效分别归因于两个可测的结构量：**对角跨度决定有没有收益，耦合度决定收益打几折。**

我们也留下了两个诚实的负结果：实用配置下逐点收缩证书失效（5.5 节），以及即使拿到真实对角曲率、耦合问题仍会发散（4.6 节）。这两条比"又快了多少倍"更能说明方法的边界在哪里。

如果要给这份作业留一句话：**一个好的梯度类方法不该只在某个问题上快，而应该能说清自己在什么结构上快、为什么快、以及为此放弃了什么保证。** AIPG 做到了前两点，第三点靠删掉一个漂亮但站不住的结论来做到；低秩修正与留出集验证是下一步。

附录 A　证明细节

命题 1：见 4.2。**定理 1**：见 4.3。**定理 2**：由 $u_i \le \hat{L}$ 得 $\alpha_i \ge 1/u_i \ge 1/\hat{L}$，故 $-g^\top Dg \ge \|g\|^2/\hat{L}$；Armijo 给出每步下降至少 $c\|g_k\|^2/\hat{L}$，求和得 $\sum_k \|g_k\|^2 \le (\hat{L}/c)(f_0 - f^\star)$；凸性给出 $f_k - f^\star \le D\|g_k\|$（$D = \|x^0 - x^\star\|$，需要迭代点保持在球内，这一点在凸情形下由 $\|x^k - x^\star\| \le \|x^0 - x^\star\|$ 不能自动保证，故该速率是**条件性**的：在 f 的次水平集有界时成立，或等价地取 D 为次水平集的半径）。**定理 3**：$\|g\|^2 \ge 2\mu(f - f^\star)$ 代入每步下降即得 $(1 - 2c\mu/\hat{L})^K$。

附录 B　复现

```
python3 -m venv --system-site-packages .venv && .venv/bin/pip install -r requirements.txt
.venv/bin/python -m forge.bench --suite full --seeds 3 --tag final_s3   # 主表（约 80 s）
.venv/bin/python -m forge.search --proposer recorded                     # 设计循环（离线重放）
.venv/bin/python -m forge.plots --raw results/raw/final_s3.jsonl         # 图
.venv/bin/python report/build.py                                        # 本 PDF
```

所有数字都能追溯到 `results/raw/final_s3.jsonl`、`results/tables/final_s3_summary.csv` 与 `design_log/rounds.jsonl`。