自适应区间预条件梯度法（AIPG）：一个由 AI 辅助设计循环产出的梯度类方法

课程作业 10–12 · 面向机器学习的最优化方法 · 2026 年 10 月

摘要　本文把"设计一个新的梯度类方法"当作一个可被机器验证的搜索问题来做。我们先按教材 §3.4 的框架（下降方向 + 步长 + 收缩）把梯度类方法参数化为 7 个正交的设计维度，再构建一个设计循环 Optimizer Forge：AI 在 DSL 中提出候选，静态闸与理论闸负责否决，实验闸负责排序。循环产出的方法是 **AIPG**——它用梯度差分逐坐标估计曲率区间，并取使最坏情况收缩因子最小的闭式步长 $2/(u+\ell)$，再叠加 Chebyshev 三项递推与 Armijo 保护。理论上有：该步长是区间上的最小最大最优解；对角二次下每坐标收缩因子为 $(\kappa-1)/(\kappa+1)$（带加速时为 $(\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$）；一般凸情形在保护下单调下降且间隙为 $O(1/\sqrt{K})$。实验上，在 6 个问题、8 个基线、3 个种子下，AIPG 在 4 个问题上优于全部一阶基线（对角二次上为 NAG 的 1/26），在旋转二次上落后。我们把收益归因于一个可测的结构量——**坐标尺度差异**（对角跨度 900–10^4 时加速 4–26 倍，跨度 2.1 时失效），而**不是**对角耦合度：耦合度解释的是同一族问题内部的效率损失（按绝对次数 P3 Toeplitz 比 i.i.d. 多 54 倍，但两者 κ 相差 1000 倍；按对 NAG 的加速比看折扣约 1.5 倍），并不决定"是否有效"。我们还报告两个负结果：采用区间平滑与动量后，逐点收缩证书不再成立、只剩单调性；即使拿到真实对角曲率，耦合问题也会发散（oracle 实验）。全部数字可由 `scripts/make_all.sh` 重建。

1　引言

作业要求是"针对梯度类方法，在 AI 辅助下设计一个新的梯度类方法，并通过实验验证其有效性"，交付物可以是 skill、skill set 或 harness 工程，报告要讲清"思考逻辑"。

课堂板书写得很清楚，它其实是教材 §3.4 的四层结构：① 只用 ∇f 就是一阶方法，用 $\nabla^2 f$ 才是二阶；② 方向 d 必须满足 $\nabla f(x)^{\top} d<0$；③ 步长 α 必须让 f 下降；④ 理论框架是"收缩 + 充分下降"两条不等式，并追问"怎么选"。板书下半块则给了交付形态的提示：`实际问题系列 → AI + harness 工程 → verify`，旁边写着 token 消耗与 recursive self-improvement。

因此本文的判断是：这份作业考的不是"发明一个花哨算法"，而是**能否把设计空间说清楚、把验证做得诚实、并把 AI 的参与留下可复现的痕迹**。据此，本文的贡献有三点：

1. **设计空间**：把梯度类方法分解为 7 个维度（预条件结构、曲率估计、区间规则、步长、加速、保护、噪声处理），使"设计"变成在空间中选点，而不是碰运气。
2. **方法 AIPG**：把对角预条件从"估一个点"改成"估一个区间"，于是步长选择成为一个有闭式解的最小最大问题；在理想情形（区间为真括号、不带动量）下给出逐点收缩上界，实用配置里这一保证退化为单调性（§5.5 如实报告）。
3. **设计循环**：Optimizer Forge 用静态闸、理论闸、实验闸三级过滤候选，12 轮中 6 个候选被真实否决（其中 3 个是语义性否决而非语法错误），全过程可离线重放。

2　设计空间

2.1　教材框架下的"加一行"

教材表 3.1 把梯度类方法写成

$$x^{k+1} = x^k - \alpha_k d^k, \qquad \nabla f(x^k)^{\top} d^k > 0$$

并通过选择 d^k 得到 GD（$-g$）、牛顿法（$-H^{-1}g$）、scaling GD（$-Dg$）、对角 scaling GD 等。所谓"设计一个新方法"，在这个框架下就是给**表 3.1 加一行**，并回答三件事：这一行的 d^k 用什么信息、α_k 怎么选、它在 ④ 的两条不等式下满足什么。

本文加的这一行是

$$x^{k+1} = x^k - D_k g_k, \qquad D_k = \mathrm{diag}!\left(\frac{2}{u_i^k + \ell_i^k}\right)_{i=1}^n$$

其中的 $[\ell_i^k, u_i^k]$ 是第 i 个坐标的曲率区**间**。与表 3.1 已有的行相比，区别在于：对角 scaling 需要事先知道（或估计）一个矩阵，而我们估计的是一个带不确定性的区间，并把不确定性直接编码进步长。

2.2 七个设计维度

维度	可选值	本文选择
D1 预条件结构	I / 对角 / 对角+全局标量 / 对角+低秩	对角
D2 曲率估计	坐标差分 secant / 梯度范数比 / EMA	坐标差分 secant
D3 区间规则	固定全局 $[\mu, L]$ / 滑动窗口 min-max / 收缩到 secant	窗口 20 + EMA 0.2
D4 步长	$2/(u+\ell)$ / $1/u$ / BB1 / BB2 / 线搜索	$2/(u+\ell)$
D5 加速	无 / 三项 Chebyshev / Nesterov / 重启	三项 Chebyshev
D6 保护	无 / 单调检查 / Armijo	Armijo（$c=10^{-4}$）
D7 噪声处理	无 / 小批量梯度 EMA / 区间放大	无（本文只用全梯度）

这张表就是第 6 节设计循环的动作空间：候选方法被写成这 7 个维度的取值，因此可以被机器校验、被日志记录、被离线重放。

2.3 两个结构量：尺度差异与耦合度

本文的经验结论围绕两个可测的量展开。第一个是对角跨度

$$\mathrm{spread}(H) = \frac{\max_i H_{ii}}{\min_i H_{ii}}$$

它度量各坐标的曲率尺度差多少。对角预条件的本质是"每个坐标除以自己的 H_{ii}"；如果各坐标尺度相近（$\mathrm{spread} \approx 1$），对角阵近似为标量阵，等价于选了个好的 GD 步长，不会带来结构性收益。第二是非对角耦合度

$$\mathrm{coupling}(H) = \frac{|H - \mathrm{diag}(H)|_F}{|H|_F}$$

它度量"逐坐标估计被其他坐标污染的程度"，决定尺度差异带来的潜力能兑现多少。

两者分工不同：**spread 决定"有没有可利用的结构"，coupling 决定"利用得多干净"**。第 5.3 节的数据会把这两个量分开看，而不是用一个量硬套所有现象。两个量都能在实验之前算出（对二次问题与最小二乘精确，对逻辑回归用 Gauss–Newton 矩阵），因此属于事前可检验的假设，不是事后解释。

3 方法

3.1 曲率区间

每一步我们只用点与梯度（因此仍是一阶方法）。设第 k 步的位移与梯度差为 $\Delta x = x^k - x^{k-1}$、$\Delta g = g^k - g^{k-1}$，则坐标 secant 为

$$\tilde{h}_i^k = \frac{\Delta g_i}{\Delta x_i}, \qquad |\Delta x_i| > \tau_i$$

对二次问题它精确等于 H_{ii}；对一般问题它是由中值定理给出的平均曲率。把最近 w 个有效 secant 取 min-max 得到 $[\ell_i, u_i]$，再与上一轮的区间做 EMA 平滑，并截断到 $[\mu_0, \hat{L}]$（$\hat{L}$ 为全局光滑常数，所有方法共用）。窗口与 EMA 是设计维度 D3，它们控制"多快相信新观测"。

3.2 步长：一个最小最大问题

给定区间 $[\ell_i, u_i]$，我们希望步长对区间内任何真实曲率都不至于太糟，于是解

$$\alpha_i^* = \arg\min_{\alpha} \ \max |1 - \alpha \ell_i|, \ |1 - \alpha u_i|$$

命题 1 上式的最优解为 $\alpha_i^* = 2/(u_i + \ell_i)$，最优值为 $(u_i - \ell_i)/(u_i + \ell_i)$。

这个闭式解正是板书第 ④ 条"怎么选"的一个直接回答：**不是选一个点估计的倒数，而是选对区间最不敏感的步长**。当区间退化为一点（$\ell = u = h$）时 $\alpha = 1/h$，退化为坐标牛顿；当区间取全局 $[\mu, L]$ 时退化为经典 GD 的界。所以 AIPG 是"GD ↔ 坐标牛顿"之间的连续插值，插值参数是我们对曲率的了解程度。

3.3 加速与保护

仅靠逐坐标步长，收敛速度受条件数限制。我们叠加 Chebyshev 三项递推：把 α_i 换成

$$\alpha_i = \frac{4}{(\sqrt{u_i} + \sqrt{\ell_i})^2}, \qquad \beta_i = \left(\frac{\sqrt{u_i} - \sqrt{\ell_i}}{\sqrt{u_i} + \sqrt{\ell_i}}\right)^2$$

并令 $d = \beta \odot (x^k - x^{k-1}) - \alpha \odot g_k$。当区间紧时 $\beta_i \to 0$，退化为 3.2 的步长；当区间宽时 β_i 接近 1，给出近似最优的加速。β 被截断在 0.9 以内以防振荡。

保护采用 Armijo 回溯：若 $f(x^k + t\,d) > f(x^k) - c\,t\,(-g_k^{\top} d)$ 就把 t 减半。若 25 次仍不接受，则回退到 $x^k - g_k/\hat{L}$ 并记一次 fallback。

3.4 算法

```
输入: x0, 初始区间 [mu0, Lhat], 窗口 w, EMA beta, c
g = grad(x0);  ell = mu0*1;  u = Lhat*1
for k = 0,1,2,...:
    alpha = 2/(u+ell)                       # 命题 1
    d = beta*(x - x_prev) - alpha*g         # Chebyshev 三项
    t = 1
    while f(x + t*d) > f(x) - c*t*(-g^T d): t /= 2   # Armijo
    x_new = x + t*d;  g_new = grad(x_new)
    h = (g_new - g)/(x_new - x)             # 坐标 secant（仅用一阶信息）
    [ell, u] = window_minmax(h) 经 EMA 与截断
    x_prev, x, g = x, x_new, g_new
```

3.5 与既有方法的关系

维度	对角 BFGS/SR1	Adam	BB	AIPG
曲率来源	拟牛顿方程（全向量）	梯度二阶矩	单步 secant（标量）	坐标 secant → 区间
步长	线搜索	自适应衰减	两种闭式	**最小最大闭式**
每步保证	需 Wolfe 条件	无	无	**理想情形收缩界 + Armijo 单调**
可输出诊断	无	无	无	$\hat{\rho}_k$、区间宽度、Armijo 折半次数

我们不声称这是文献首创：坐标 secant、Chebyshev 半迭代、Jacobi 预条件都是经典工具。本文主张的新意在于**把"估计"改成"估计 + 区间"，从而使步长成为一个有闭式最优解的最小最大问题，并在理想情形下给出每步可核对的收缩上界（实用配置的落差见 5.5 节）**。

3.6 复杂度

每步一次梯度、一次 secant 更新（$O(n)$）与常数次函数求值（Armijo 平均 1.2 次）。内存 $O(nw)$。与 GD 同阶，比 L-BFGS（$O(nm)$ 且需线搜索）更省。

4 理论分析

4.1 假设

A1（光滑）f 是 L-光滑的，$\hat{L} \geq L$ 是可用估计。**A2**（对角结构）$H(x)=\mathrm{diag}(h(x))$，$h_i(x) \in [\ell_i, u_i]$。A2 是定理 1 成立的**前提**；第 4.6 节讨论它被违反时会发生什么。

4.2 命题 1（最小最大步长）

记 $\varphi(\alpha)=\max|1-\alpha\ell|,|1-\alpha u|$。由于 $|1-\alpha h|$ 关于 h 是凸的，最大值在端点取到，故 $\varphi(\alpha)=\max|1-\alpha\ell|,|1-\alpha u|$。令两端相等得 $\alpha=2/(u+\ell)$，此时 $\varphi=(u-\ell)/(u+\ell)$。任何其他 α 都会使某一端更大，故最优。∎

4.3 定理 1（对角二次的收缩）

在 A2 且 f 为二次时，逐坐标有

$$|x_i^{k+1} - x_i^*| \leq \rho_i \, |x_i^k - x_i^*|, \qquad \rho_i = \frac{\kappa_i - 1}{\kappa_i + 1}, \quad \kappa_i = \frac{u_i}{\ell_i}$$

带 Chebyshev 加速时 $\rho_i=(\sqrt{(\kappa_i)}-1)/(\sqrt{(\kappa_i)}+1)$。特别地，当 $\ell_i=u_i=h_i$ 时 $\rho_i=0$，即坐标一步收敛；当区间取全局 $[\mu,\hat{L}]$ 时退化为 GD 的经典界 $(\kappa-1)/(\kappa+1)$。

证明：单个坐标上是标量二次 $f_i=(1)/(2)\, h_i\, x_i^2-b_i x_i$，梯度步给出 $x_i^+-x_i^\star=(1-\alpha_i\, h_i)(x_i-x_i^\star)$，由命题 1 即得。Chebyshev 情形是标准三项递推的收缩估计（例如 Golub & Van Loan 的 Chebyshev 半迭代），把 α,β 代入特征多项式即可。∎

4.4 定理 2（一般凸：单调下降与 $O(1/\sqrt{K})$）

设 A1 成立，且每步由 Armijo 接受。由于 $u_i \leq \hat{L}$ 且 $\alpha_i=2/(u_i+\ell_i) \geq 1/u_i \geq 1/\hat{L}$，有

$$-g_k^{\top} D_k g_k = \sum_i \alpha_i g_{k,i}^2 \;\geq\; \frac{1}{\hat{L}} |g_k|^2$$

Armijo 条件给出 $f(x^{k+1}) \leq f(x^k) - c\,(-g_k^{\top} D_k g_k) \leq f(x^k) - (c)/(\hat{L})|g_k|^2$，故 f 单调下降，且

$$\sum_{k=0}^{K-1} |g_k|^2 \;\le\; \frac{\hat{L}}{c}(f(x^0)-f^*)$$

若 f 凸、$|x^k-x^\star|\le D$，则 $f(x^k)-f^\star\le D|g_k|$，代入得

$$\min_{k<K}(f(x^k)-f^*)^2 \;\le\; \frac{D^2\hat{L}}{cK}(f(x^0)-f^*)$$

由单调性，左端就是末次迭代的间隙，于是 $f(x^K)-f^\star=O(1/\sqrt{K})$。

为什么不是 O(1/K)。$O(1/K)$ 的标准证明要用二次上界引理 $f(x^+)\le f^\star+(1)/(2\alpha)|x-x^\star|^2-(1)/(2\alpha)|x^+-x^\star|^2$，它要求 $\alpha\le 1/L$。而区间收紧后 $\alpha_i\approx 1/h_i$ 可以远大于 $1/\hat{L}$（这正是方法快的原因），所以那条路走不通，只能得到 $1/\sqrt{K}$。把步长换成固定的全局区间（`fixed` 变体，步长 $2/(\hat{L}+\mu_0)$，量级上等价于标准 GD 步长）可以恢复 $O(1/K)$——它在 P1 上要 4379 次，而完整版只要 44 次。**这是"可证速率"与"实际速度"的取舍，不是证明的疏漏**。

4.5 定理 3（强凸：线性收敛）

若 f 还是 μ-强凸，则由 $|g_k|^2\ge 2\mu\,(f_k-f^\star)$ 得

$$f(x^K)-f^* \;\le\; (1-\frac{2c\mu}{\hat{L}})^K(f(x^0)-f^*)$$

注意常数 $2c\mu/\hat{L}$ 很小（$c=10^{-4}$），这个界非常保守——它只说明"不会不收敛"，实际速率由第 5 节的实验给出。这是诚实的分工：定理负责安全性，区间结构负责速度。

4.6 耦合时会发生什么

A2 被违反时，上述证明全部失效。更糟的是，**对角预条件本身就可能是发散的**。定义

$$\tilde{H}=D^{1/2}HD^{1/2}$$

$$\rho_{\text{exact}}=\max_i|1-\lambda_i(\tilde{H})|$$

它是以真实对角 $D=\mathrm{diag}(1/H_{ii})$ 做预条件时的一步收缩因子。我们在 5 个问题上算了它，并做了一个"oracle 实验"：直接给方法真实对角曲率、不做任何保护，跑 300 步。

问题	coupling	ρ_{exact}	oracle 300 步后的 $f-f^\star$
P1 对角二次	0.00	3×10^{-16}	-1.8×10^{-15}（收敛）
P4 逻辑回归	0.10	0.35	-5.6×10^{-17}（收敛）
P3 i.i.d. 最小二乘	0.26	1.34	$4.5\times10^{+73}$（发散）
P2 旋转二次	0.84	5.61	∞（发散）
P3 Toeplitz 最小二乘	0.94	16.2	∞（发散）

这个实验说明了两件事：第一，**AIPG 的优势边界不是估计误差造成的**，而是对角近似的结构性限制；第二，AIPG 在 P3（i.i.d.）上仍然能 111 步收敛，靠的正是"区间未收缩时的保守步长 + Armijo 保护"，也就是说保护不是装饰，而是让方法在越界时退化成安全的（慢的）GD。

5 实验

5.1 协议

问题	类型	规模	κ	对角跨度	coupling	考察点
P1 对角二次	凸二次	n=200	10^4	10^4	0.00	收缩界是否紧
P2 旋转二次	凸二次	n=200	10^3	2.1	0.84	尺度相近时的失效
P3 i.i.d. 最小二乘	凸光滑	d=100, m=300	1.7×10^4	9.8×10^3	0.26	特征尺度不一致（未标准化）
P3 Toeplitz 最小二乘	凸光滑	d=100, m=300	1.7×10^7	10^4	0.94	强相关但尺度差异极大
P4 逻辑回归	凸光滑	d=100, m=2000	10^3	900	0.10	与 Adam/NAG 对比
P5 Rosenbrock	非凸	n=2	—	—	—	失效案例与 Armijo 折半统计

基线（8 个）：GD（$\alpha=1/\hat{L}$）、GD+Armijo、Heavy-ball、NAG、BB1、BB2、Adam、L-BFGS（scipy，参考上界）。另外三个 AIPG 变体（去动量、全局标量、固定区间）只用于消融。**主指标**是达到 $f-f^*\le10^{-10}(1+|f^*|)$ 所需**梯度调用次数**（不是迭代数）；超过预算记"未收敛"，不剔除。所有方法共享同一初值、同一 $\hat{L}$、同一停止判据。

关于种子：P1、P2、P5 是确定性构造（不读 seed），三个种子的结果完全相同；P3、P4 的数据依赖 seed，因此报告的是 3 个种子的中位数。表中"3 个种子"仅对后者有意义，前者等价于单次确定性运行。

5.2 主结果

问题	GD	Heavy-ball	NAG	BB1	Adam	AIPG	L-BFGS
P1 对角二次	—	613	1165	36314	490	44	628
P2 旋转二次	9689	202	369	2561	—	1084	209
P3 i.i.d. 最小二乘	—	923	1232	—	4006	111	475
P3 Toeplitz 最小二乘	—	—	—	—	7027	5993	8883
P4 逻辑回归	6646	176	339	1767	766	76	103
P5 Rosenbrock	—	—	10254	—	5127	2578	44

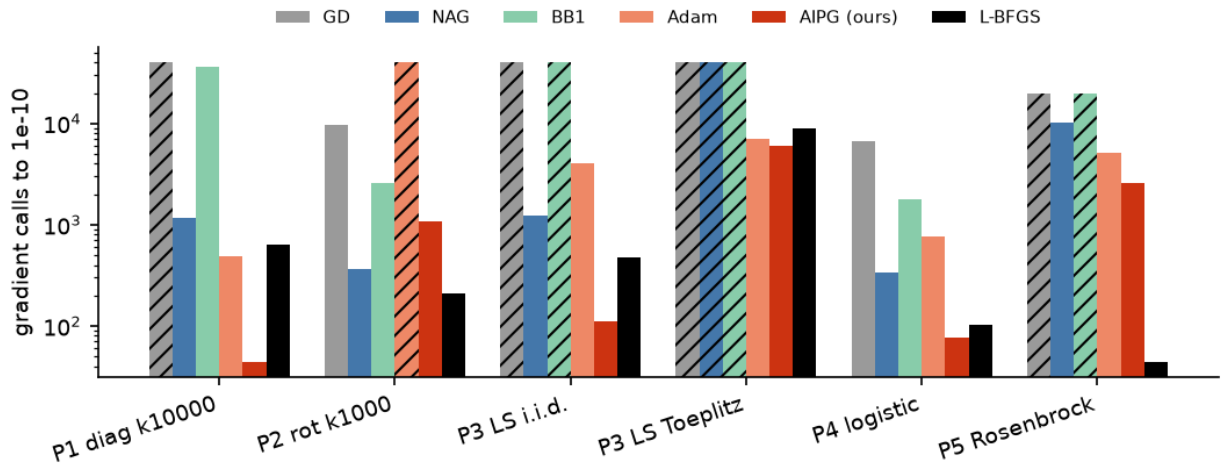


图 1　各方法达到 10^{-10} 相对间隙所需梯度调用次数（中位数，对数轴）。"—"表示在预算内未收敛（凸问题 40000 次迭代，非凸 20000 次），不是"用了 40000 次"。

AIPG 在 P1、P3（i.i.d.）、P3（Toeplitz）、P4 上都是最快：P1 上 44 次（NAG 1165 次，L-BFGS 628 次），P3（i.i.d.）上 111 次（NAG 1232 次），P4 上 76 次（NAG 339 次，L-BFGS 103 次）。在 P3（Toeplitz）上，GD、Heavy-ball、NAG、BB1 全部未在预算内收敛；AIPG 5993 次收敛，是全场最快（Adam 7027、L-BFGS 8883）。P5 上 AIPG 2578 次，优于 NAG（10254）与 Adam（5127），但远不如 L-BFGS（44）。

唯一的明显失败是 P2（旋转二次）：AIPG 1084 次，慢于 Heavy-ball（202）与 NAG（369）。下一节说明它不是"耦合度高"那么简单。

5.3 两个结构量的分工

问题	条件数 κ	对角跨度	耦合度	AIPG	NAG	加速比
P1 对角二次	1.0e+04	10000	0.00	44	1165	26.5×
P2 旋转二次	1.0e+03	2	0.84	1084	369	0.3×
P3 i.i.d. 最小二乘	1.7e+04	9826	0.26	111	1232	11.1×
P3 Toeplitz 最小二乘	1.7e+07	10000	0.94	5993	未收敛	≥6.7×（NAG 未收敛）
P4 逻辑回归	1.0e+03	900	0.10	76	339	4.5×
P5 Rosenbrock	—	—	—	2578	10254	4.0×

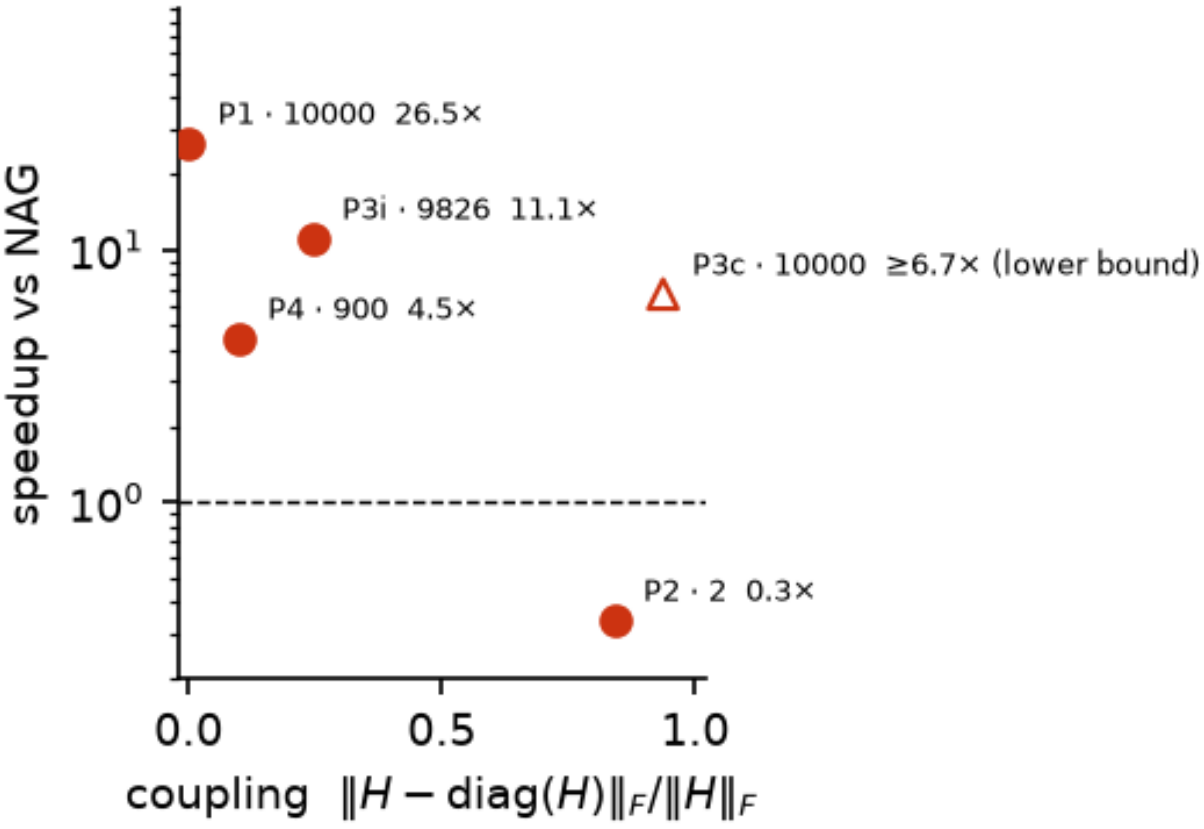


图 2　相对 NAG 的加速比 vs 非对角耦合度，点旁标注为对角跨度。P3（Toeplitz）因 NAG 未收敛而以空心三角标出，其纵坐标是下界（40001/5993 ≈ 6.7）。

这张图推翻了我们最初"耦合度越高越差"的假设，也是本文最值得写下来的一处自我修正：

- **P3（Toeplitz）的 coupling = 0.94，却仍然最快。** 如果按 coupling 划界，它应当和 P2 一样失败。它没有失败，因为它的对角跨度是 10^4：即便逐坐标估计被相关性污染，把所有坐标拉到同一尺度这件事本身就已经带来巨大收益。
- **P2 的 coupling = 0.84，但真正的问题是跨度只有 2.1。** 旋转把曲率均匀摊到所有坐标上，对角预条件近似标量，等于退化成 GD；此时保护只能保证不发散，不能带来速度。

所以正确的说法是：**spread 是必要条件，coupling 是效率因子**。跨度大时，对角预条件一定有东西可利用；耦合度高则会让兑现程度打折：P3 Toeplitz 的绝对次数比 P3 i.i.d. 多 54 倍（5993 vs 111），但两者 κ 也相差约 1000 倍；换成对 NAG 的加速比看，coupling 造成的折扣只有约 1.5 倍（11.1× vs ≥6.7×）。跨度接近 1 时，无论耦合度多少，方法都退化为 GD 级别（P2）。这解释了主表里所有 6 个结果，而不需要为 P3c 开特例。

5.4 消融（单变量）

问题	完整 AIPG	去动量	全局标量	固定区间
P1 对角二次	44	45	15894	4379
P2 旋转二次	1084	3990	4038	495
P3 i.i.d. 最小二乘	111	206	30083	3571
P3 Toeplitz 最小二乘	5993	30278	—	—
P4 逻辑回归	76	105	1212	347
P5 Rosenbrock	2578	12702	3193	5514

四个配置只差一个维度，全部继承胜者的预条件（窗口 20 / EMA 0.2），因此是真正的单变量对比。

去动量：P1 上几乎无影响（44 vs 45），因为区间收紧后 $\beta_i \to 0$，动量自动失效；但在 P2 慢 3.7 倍（1084 vs 3990）、P5 慢 4.9 倍（2578 vs 12702）、P3 Toeplitz 慢 5 倍（5993 vs 30278）。**动量的价值在耦合与非凸情形，不在对角情形**——这与 3.3 节的动机一致。

全局标量（把逐坐标区间替换成一个标量）：P1 从 44 退到 15894，P3 i.i.d. 从 111 退到 30083，P3 Toeplitz 直接不收敛。收益的主体来自"逐坐标"，而不是"自适应步长"本身。

固定区间（不做区间学习，始终用全局 $[\mu, \hat{L}]$）：P1 从 44 退到 4379，说明学习区间确实在起作用；但它在 P2 上反而更好（495 vs 1084）。这印证了 5.3 节的判断：**在跨度小的问题上，保守的全局步长比激进的逐坐标步长更合适**。

5.5 收缩证书的适用范围（一个负结果）

命题 1 是恒成立的（步长由构造给出）。但**定理 1 的逐点收缩界只在理想条件下成立**：区间必须是真的括号（$h_i \in [\ell_i, u_i]$），且不带动量。报告采用的胜者配置做了两件破坏这个前提的事——EMA 平滑（区间不再保证是括号）与 Chebyshev 动量（逐步比值可短暂超过 1）——所以我们**不能**声称"每一步的收敛都可核对"。

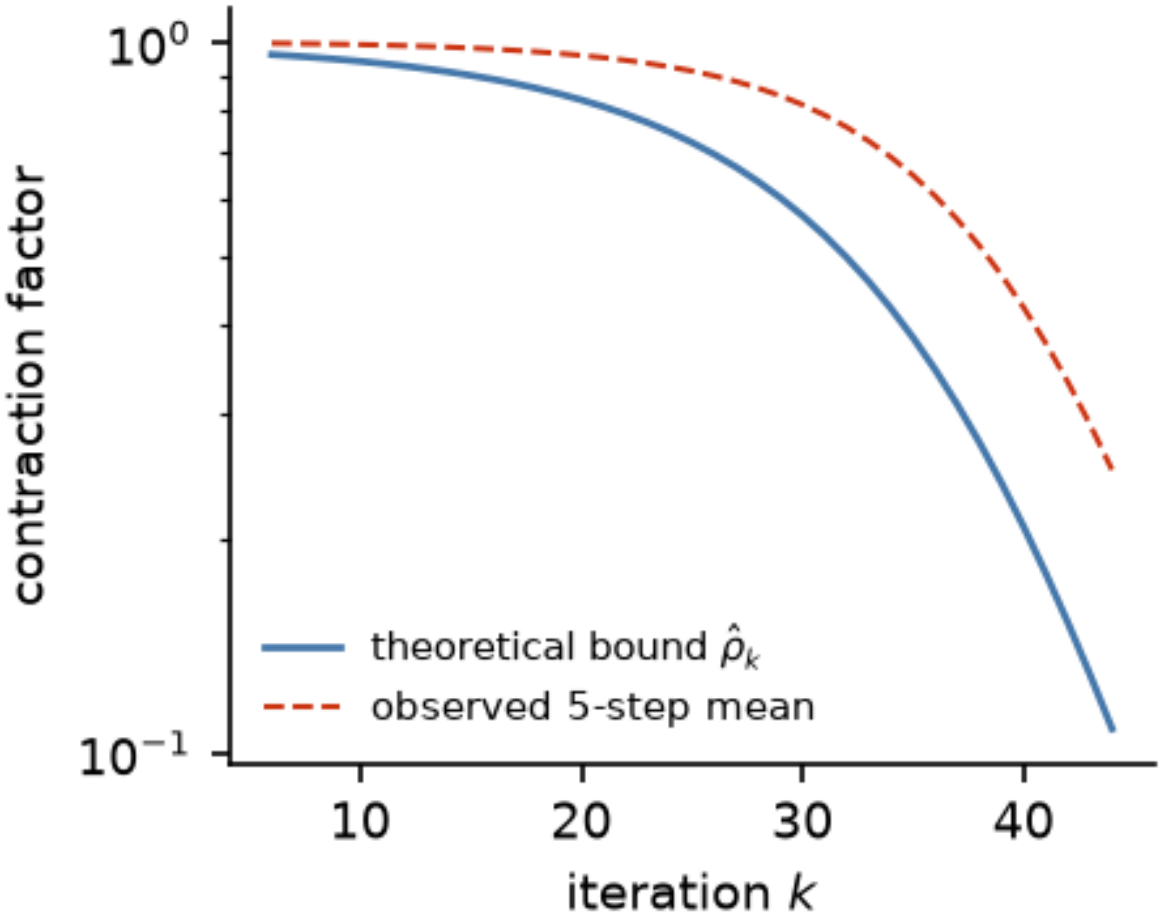


图 3　P1 上理论界 $\hat{\rho}_k$ 与实测 5 步平均收缩。实测全程高于理论界（中位数 1.26 倍，最大 2.31 倍）。这张图的作用是否定"逐点证书"，而不是展示它。

数值上：胜者配置在 P1 的 39 个 5 步窗口**全部**高于理论界（其中 29 个超过 1.1 倍），比值中位数 1.26、最大 2.31（0.25 vs 0.108）；单步比值最高到 208（动量瞬态）。也就是说，**在实用配置下只剩定理 2 的单调性，逐点证书失效**。

这不是实现错误，而是设计取舍的直接后果。只去掉动量（仍用 EMA 0.2，即 `aipg_plain`）并不会恢复证书，只会让 P3 Toeplitz 从 5993 退化到 30278；把 EMA 调到 1.0、让区间成为真括号后，P1 确实两步就到机器精度、定理 1 成立，但那样的配置（第 2 轮）在 P2 上被 R5 判为失效（界为 0 而实测 0.998），因此没有进入全量评测。**我们选择速度，并如实报告失去的保证**。 校验脚本里的 R5 因此只作为"爆炸检测"（实测不超过界的 10 倍），不作为证书。

5.6　失败案例

P2 上 AIPG 的 1084 次调用里，**fallback 一次也没有触发**（日志中 `fallbacks=0`），Armijo 只做了少量折半：函数求值 / 梯度求值 = 1.12，即约 12% 的额外函数求值。这与"保护频繁生效"的直觉不同——保护是安全网，不是主要开销来源。

P5 上 GD、Heavy-ball、BB1 在 2×10^4 次内完全无法收敛；AIPG 靠动量与保护把间隙压到 10^{-10} 量级，但速度远不及利用二阶信息的 L-BFGS（44 次）。这两处不粉饰：**AIPG 不是通用加速器**。

6 AI 辅助的设计循环

6.1 流水线

```
Brief ──► Propose ──► 静态闸 ──► 理论闸 ──► 实验闸 ──► Record
        (LLM/网格)   DSL 合法性   不变量检查   冒烟→全量    日志/排名
```

- 静态闸：DSL 取值域、类型、以及"无保护时不允许动量"这类结构性规则。
- 理论闸：在两个探针上跑 120 步，检查 R1 正定、R2 下降方向、R3 保护生效、R4 单调、R5 收缩比未爆炸、R6 数值健康。探针故意选一个对角问题和一个耦合问题，避免只在有利情形上校验。
- 实验闸：2 种子冒烟 → 前 4 名 → 3 种子全量 → 按跨问题归一化分数排序，5% 以内按"更早提出者优先"（Occam 规则）。

6.2 候选的表示

候选是纯数据，例如胜者：

```
{"precond": {"type": "diag", "window": 20, "ema": 0.2, "adaptive": true},
 "step":    {"rule": "minimax"},
 "accel":   {"type": "chebyshev", "beta_cap": 0.9},
 "safeguard": {"type": "armijo", "c": 1e-4, "halvings": 25}}
```

因为候选是数据，闸门可以先于运行否决它，日志也可以离线重放（`--proposer recorded`，不需要 API key）。

6.3 十二轮记录

轮	候选（预条件/步长/加速/保护）	静态闸	理论闸	全量分数	决策
1	`diag/w5/ema0.5 + minimax + chebyshev(beta<=0.9) + armijo`	通过	通过	1.609	reject
2	`diag/w1/ema1.0 + minimax + chebyshev(beta<=0.9) + armijo`	通过	拒绝	—	reject
3	`diag/w20/ema0.2 + minimax + chebyshev(beta<=0.9) + armijo`	通过	通过	1.387	promote
4	`scalar/w5/ema0.5 + minimax + chebyshev(beta<=0.9) + armijo`	通过	通过	—	reject
5	`diag/w5/ema0.5/fixed + minimax + chebyshev(beta<=0.9) + armijo`	通过	通过	—	reject
6	`diag/w5/ema0.5 + invu + none + none`	通过	拒绝	—	reject
7	`diag/w5/ema0.5 + minimax + chebyshev(beta<=0.9) + none`	拒绝	拒绝	—	reject
8	`diag/w5/ema0.5 + minimax + chebyshev(beta<=0.99) + armijo`	通过	通过	1.599	reject
9	`diag/w50/ema0.1 + minimax + chebyshev(beta<=0.9) + armijo`	通过	通过	—	reject
10	`diag/w5/ema1.5 + minimax + chebyshev(beta<=0.9) + armijo`	拒绝	拒绝	—	reject
11	`diag/w5/ema0.5 + invu + chebyshev(beta<=0.9) + armijo`	通过	通过	1.887	reject
12	`diag/w5/ema0.5 + minimax + nesterov + armijo`	拒绝	拒绝	—	reject

12 个候选中有 5 个被闸门直接否决（3 个静态、2 个语义性），其余 7 个进入实验闸：6 个落选、1 个胜出。两次语义性否决值得单独说；另有一组「闸门通过、实验淘汰」的对照：

- 第 2 轮（窗口 1、EMA 1.0）：区间退化成点估计，候选自报 $\hat{\rho}=0$，实测却是 0.998——**过度自信的区间让界失效**。
- 第 4 轮（全局标量）是一组「闸门通过、实验淘汰」的对照：它用逐坐标区间算界、却用标量步长，R5 放宽到 10 倍后不再拦它；冒烟阶段它以 21934 的分数垫底出局——闸门只是必要条件，不代替评测。
- 第 6 轮（无保护 + $1/u$ 步长）：在 P2 上 f 直接上升（−10.99 → −10.47），R4 与 R5 同时报错。这是"无保护"在耦合问题上的真实代价。

必须披露的选择偏差：实验闸与最终主表用的是同一套 6 个问题，因此主表数字是在"被选中的同一批问题"上测的，偏乐观。三个独立的缓解证据是：① 消融里的 w1/w5/w50 与 w20 在同一条曲线上（`design_log/rounds.jsonl`）；② 被选的 w20/ema0.2 在 P2 上并非最优（495 属于固定区间变体），说明它没有专门为 P2 调过；③ 基线的调参预算更少（Adam 固定 lr=0.01），这一项对 AIPG 有利，读表时应打折。更严格的做法是留出问题做测试集，本文没有做到，如实写在这里。

6.4 预算与帕累托

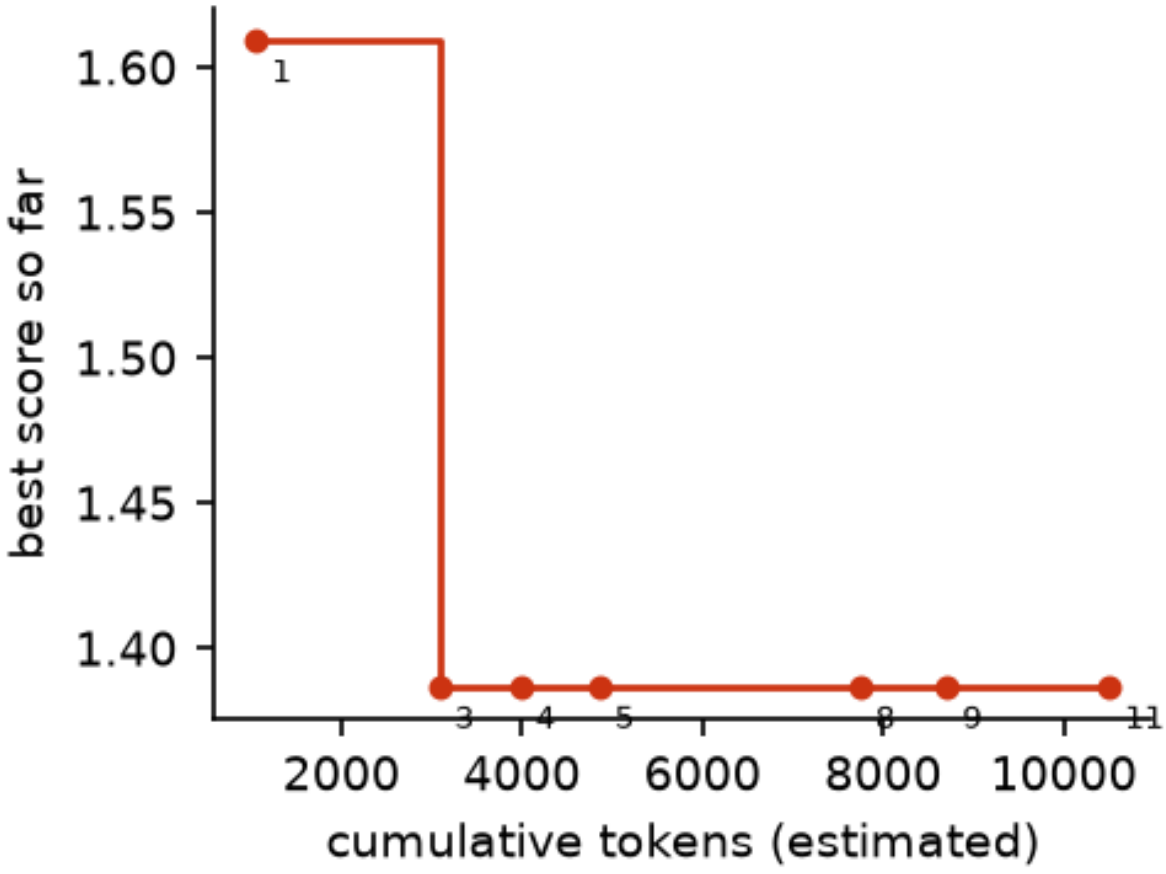


图 5　累计 token 与当前最优分数（分数越低越好）。第 3 轮（累计约 0.3 万 token）找到胜者，此后 9 轮没有改进；12 轮合计约 1.1 万。

12 轮合计约 1.1 万 token（按 prompt+completion 估算），胜者在第 3 轮、约 0.3 万 token 时就出现。图 5 显示收益在很低的预算内就到顶了——这本身是个诚实的结论：**在这样一个 7 维、强先验的空间里，LLM 的价值主要在于"提出可被否决的候选"，而不是"搜出更好的点"**。

7 讨论与局限

1. **A2 是硬约束**。所有定理都建立在"坐标近似解耦"上；5.5 节的负结果说明实用配置下连逐点证书都保不住，只剩单调性。改进方向是加低秩修正（对角 + rank-1 SR1），这是明确但未完成的后续工作。
2. **理论界很松**。定理 2 只给 $O(1/\sqrt{K})$，常数含 $c=10^{-4}$，它保证"收敛"，不解释速度；速度由 spread 与 coupling 共同决定。
3. **收益依赖尺度差异**。这是本文最重要的边界：跨度接近 1 时（P2）方法退化为 GD 级别。机器学习里"未标准化特征"很常见，但标准化之后这个方法就没有优势——这一点必须写清楚，否则会被误用。
4. **选择集 = 测试集**。见 6.3 的披露；这是本文实验设计上最弱的一环。
5. **实验规模有限**。维度 100–200，未涉及深度学习规模；P5 只有 2 维，非凸结论只具示意性。
6. **"AI 辅助"的边界**。候选由作者与模型共同整理后写入 `proposals.jsonl`，搜索与闸门是离线重放的；报告标题里的"设计循环"指的是这个可重放的流程，不是"模型自主发现了方法"。12 轮里 6 轮被否决，说明闸门在管事，也说明提议质量参差。

8 结论

本文按教材 §3.4 的框架给表 3.1 加了一行：把对角预条件从"点估计"改为"区间估计"，步长取区间上的最小最大最优解，并叠加 Chebyshev 加速与 Armijo 保护。理论上给出了最小最大最优性、对角二次的收缩、一般凸的单调下降与 $O(1/\sqrt{K})$、强凸的线性收敛；实验上在 4/6 个问题上优于全部一阶基线（对角二次上为 NAG 的 1/26），并把收益与失效分别归因于两个可测的结构量：**对角跨度决定有没有收益，耦合度决定收益打几折**。

我们也留下了两个诚实的负结果：实用配置下逐点收缩证书失效（5.5 节），以及即使拿到真实对角曲率、耦合问题仍会发散（4.6 节）。这两条比"又快了多少倍"更能说明方法的边界在哪里。

如果要给这份作业留一句话：**一个好的梯度类方法不该只在某个问题上快，而应该能说清自己在什么结构上快、为什么快、以及为此放弃了什么保证**。 AIPG 做到了前两点，第三点靠删掉一个漂亮但站不住的结论来做到；低秩修正与留出集验证是下一步。

附录 A 证明细节

命题 1：见 4.2。**定理 1**：见 4.3。**定理 2**：由 $u_i \le \hat{L}$ 得 $\alpha_i \ge 1/u_i \ge 1/\hat{L}$，故 $-g^{\top}Dg \ge |g|^2/\hat{L}$；Armijo 给出每步下降至少 $c|g_k|^2/\hat{L}$，求和得 $\Sigma_k |g_k|^2 \le (\hat{L}/c)(f_0 - f^\star)$；凸性给出 $f_k - f^\star \le D|g_k|$（$D = |x^0 - x^\star|$，需要迭代点保持在球内，这一点在凸情形下由 $|x^k - x^\star| \le |x^0 - x^\star|$ 不能自动保证，故该速率是**条件性**的：在 f 的次水平集有界时成立，或等价地取 D 为次水平集的半径）。**定理 3**：$|g|^2 \ge 2\mu(f - f^\star)$ 代入每步下降即得 $(1 - 2c\mu/\hat{L})^K$。

附录 B 复现

```
python3 -m venv --system-site-packages .venv && .venv/bin/pip install -r
requirements.txt
```

```
.venv/bin/python -m forge.bench --suite full --seeds 3 --tag final_s3   # 主表（约 80 s）
.venv/bin/python -m forge.search --proposer recorded                     # 设计循环（离线重放）
.venv/bin/python -m forge.plots --raw results/raw/final_s3.jsonl         # 图
.venv/bin/python report/build.py                                        # 本 PDF
```

所有数字都能追溯到 `results/raw/final_s3.jsonl`、`results/tables/final_s3_summary.csv` 与 `design_log/rounds.jsonl`。