# 自适应区间预条件梯度法（AIPG）：一个由 AI 设计循环产出的梯度类方法

课程作业 10–12 · 面向机器学习的最优化方法 · 2026 年 10 月

**摘要**　本文把"设计一个新的梯度类方法"当作一个可被机器验证的搜索问题来做。我们先按教材 §3.4 的框架（下降方向 + 步长 + 收缩）把梯度类方法参数化为 7 个正交的设计维度，再构建一个设计循环 Optimizer Forge：AI 在 DSL 中提出候选，静态闸与理论闸负责否决，实验闸负责排序。循环产出的方法是 **AIPG**——它用梯度差分逐坐标估计曲率区**间**，并取使最坏情况收缩因子最小的闭式步长 $2/(u+\ell)$，再叠加 Chebyshev 三项递推与 Armijo 保护。理论上有：该步长是区间上的最小最大最优解；对角二次下每坐标收缩因子为 $(\kappa-1)/(\kappa+1)$（带加速时为 $(\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$）；一般凸情形在保护下单调下降并具 $O(1/K)$ 与线性收敛界。实验上，在 6 个问题、9 个基线、3 个种子下，AIPG 在 4 个问题上优于全部一阶基线（对角二次上为 NAG 的 1/26），并且它的优势可以被一个可测的结构量——非对角耦合度——解释：耦合度 $\le 0.26$ 时加速比为 4.5×–26×，耦合度 $\ge 0.84$ 时失效。我们把这个边界用"精确对角预条件的 oracle 实验"钉死：即使拿到真实对角曲率，耦合问题仍会发散，说明限制是结构性的而非估计误差。全部数字可由 `scripts/make_all.sh` 重建。

## 1　引言

作业要求是"针对梯度类方法，在 AI 辅助下设计一个新的梯度类方法，并通过实验验证其有效性"，交付物可以是 skill、skill set 或 harness 工程，报告要讲清"思考逻辑"。

课堂板书写得很清楚，它其实是教材 §3.4 的四层结构：① 只用 $\nabla f$ 就是一阶方法，用 $\nabla^2 f$ 才是二阶；② 方向 $d$ 必须满足 $\nabla f(x)^{\top} d<0$；③ 步长 $\alpha$ 必须让 $f$ 下降；④ 理论框架是"收缩 + 充分下降"两条不等式，并追问"怎么选"。板书下半块则给了交付形态的提示：`实际问题系列 → AI + harness 工程 → verify`，旁边写着 token 消耗与 recursive self-improvement。

因此本文的判断是：这份作业考的不是"发明一个花哨算法"，而是**能否把设计空间说清楚、把验证做得诚实、并把 AI 的参与留下可复现的痕迹**。据此，本文的贡献有三点：

1. **设计空间**：把梯度类方法分解为 7 个维度（预条件结构、曲率估计、区间规则、步长、加速、保护、噪声处理），使"设计"变成在空间中选点，而不是碰运气。
2. **方法 AIPG**：把对角预条件从"估一个点"改成"估一个区间"，于是步长选择成为一个有闭式解的最小最大问题，并且每一步都附带可核对的收缩证书。
3. **设计循环**：Optimizer Forge 用静态闸、理论闸、实验闸三级过滤候选，12 轮中 6 个候选被真实否决（其中 3 个是语义性否决而非语法错误），全过程可离线重放。

## 2　设计空间

### 2.1　教材框架下的"加一行"

教材表 3.1 把梯度类方法写成

$$x^{k+1} = x^k - \alpha_k d^k, \qquad \nabla f(x^k)^{\top} d^k > 0$$

并通过选择 $d^k$ 得到 GD（$-g$）、牛顿法（$-H^{-1}g$）、scaling GD（$-Dg$）、对角 scaling GD 等。所谓"设计一个新方法"，在这个框架下就是给**表 3.1 加一行**，并回答三件事：这一行的 $d^k$ 用什么信息、$\alpha_k$ 怎么选、它在 ④ 的两条不等式下满足什么。

本文加的这一行是

$$x^{k+1} = x^k - D_k g_k, \qquad D_k = \mathrm{diag}!\left(\frac{2}{u_i^k + \ell_i^k}\right)_{i=1}^n$$

其中的 $[\ell_i^k, u_i^k]$ 是第 $i$ 个坐标的曲率区**间**。与表 3.1 已有的行相比，区别在于：对角 scaling 需要事先知道（或估计）一个矩阵，而我们估计的是一个带不确定性的区间，并把不确定性直接编码进步长。

### 2.2 七个设计维度

| 维度 | 可选值 | 本文选择 |
|---|---|---|
| D1 预条件结构 | $I$ / 对角 / 对角+全局标量 / 对角+低秩 | 对角 |
| D2 曲率估计 | 坐标差分 secant / 梯度范数比 / EMA | 坐标差分 secant |
| D3 区间规则 | 固定全局 $[\mu, L]$ / 滑动窗口 min-max / 收缩到 secant | 窗口 20 + EMA 0.2 |
| D4 步长 | $2/(u+\ell)$ / $1/u$ / BB1 / BB2 / 线搜索 | $2/(u+\ell)$ |
| D5 加速 | 无 / 三项 Chebyshev / Nesterov / 重启 | 三项 Chebyshev |
| D6 保护 | 无 / 单调检查 / Armijo | Armijo（$c=10^{-4}$） |
| D7 噪声处理 | 无 / 小批量梯度 EMA / 区间放大 | 无（本文只用全梯度） |

这张表就是第 6 节设计循环的动作空间：候选方法被写成这 7 个维度的取值，因此可以被机器校验、被日志记录、被离线重放。

### 2.3 我们要利用的结构：对角耦合度

本文所有的分析都围绕一个可测的结构量展开：

$$\mathrm{coupling}(H) = \frac{|H - \mathrm{diag}(H)|_F}{|H|_F}$$

它度量"非对角部分占多少"。当 coupling 很小时，坐标之间近似解耦，逐坐标估计曲率是有意义的；当 coupling 接近 1 时，任何对角预条件都无法替代真正的逆 Hessian。这个量在实验之前就可以算出来（对二次问题和最小二乘是精确的，对逻辑回归用 Gauss–Newton 矩阵），因此它可以**事前**预测方法的适用性，而不是事后找借口。

## 3 方法

### 3.1 曲率区间

每一步我们只用点与梯度（因此仍是一阶方法）。设第 $k$ 步的位移与梯度差为 $\Delta x = x^k - x^{k-1}$、$\Delta g = g^k - g^{k-1}$，则坐标 secant 为

$$\tilde{h}_i^k = \frac{\Delta g_i}{\Delta x_i}, \qquad |\Delta x_i| > \tau_i$$

对二次问题它精确等于 $H_{ii}$；对一般问题它是由中值定理给出的平均曲率。把最近 $w$ 个有效 secant 取 min-max 得到 $[\ell_i, u_i]$，再与上一轮的区间做 EMA 平滑，并截断到 $[\mu_0, \hat{L}]$（$\hat{L}$ 为全局光滑常数，所有方法共用）。窗口与 EMA 是设计维度 D3，它们控制"多快相信新观测"。

### 3.2 步长：一个最小最大问题

给定区间 $[\ell_i, u_i]$，我们希望步长对区间内任何真实曲率都不至于太糟，于是解

$$\alpha_i^* = \arg\min_{\alpha} \ \max |1-\alpha\ell_i|,\ |1-\alpha u_i|$$

**命题 1** 上式的最优解为 $\alpha_i^\star = 2/(u_i+\ell_i)$，最优值为 $(u_i-\ell_i)/(u_i+\ell_i)$。

这个闭式解正是板书第 ④ 条"怎么选"的一个直接回答：**不是选一个点估计的倒数，而是选对区间最不敏感的步长**。当区间退化为一点（$\ell=u=h$）时 $\alpha=1/h$，退化为坐标牛顿；当区间取全局 $[\mu, L]$ 时退化为经典 GD 的界。所以 AIPG 是"GD ↔ 坐标牛顿"之间的连续插值，插值参数是我们对曲率的了解程度。

### 3.3 加速与保护

仅靠逐坐标步长，收敛速度受条件数限制。我们叠加 Chebyshev 三项递推：把 $\alpha_i$ 换成

$$\alpha_i = \frac{4}{(\sqrt{u_i}+\sqrt{\ell_i})^2}, \qquad \beta_i = \left(\frac{\sqrt{u_i}-\sqrt{\ell_i}}{\sqrt{u_i}+\sqrt{\ell_i}}\right)^2$$

并令 $d=\beta\odot(x^k-x^{k-1})-\alpha\odot g_k$。当区间紧时 $\beta_i \to 0$，退化为 3.2 的步长；当区间宽时 $\beta_i$ 接近 1，给出近似最优的加速。$\beta$ 被截断在 0.9 以内以防振荡。

保护采用 Armijo 回溯：若 $f(x^k+t\,d) > f(x^k) - c\,t\,(-g_k{}^{\mathsf T} d)$ 就把 $t$ 减半。若 25 次仍不接受，则回退到 $x^k - g_k/\hat{L}$ 并记一次 fallback。

### 3.4 算法

```
输入: x0, 初始区间 [mu0, Lhat], 窗口 w, EMA beta, c
g = grad(x0);  ell = mu0*1;  u = Lhat*1
for k = 0,1,2,...:
    alpha = 2/(u+ell)                          # 命题 1
    d = beta*(x - x_prev) - alpha*g            # Chebyshev 三项
    t = 1
    while f(x + t*d) > f(x) - c*t*(-g^T d): t /= 2   # Armijo
    x_new = x + t*d;  g_new = grad(x_new)
    h = (g_new - g)/(x_new - x)                # 坐标 secant（仅用一阶信息）
    [ell, u] = window_minmax(h) 经 EMA 与截断
    x_prev, x, g = x, x_new, g_new
```

### 3.5 与既有方法的关系

| 维度 | 对角 BFGS/SR1 | Adam | BB | AIPG |
|---|---|---|---|---|
| 曲率来源 | 拟牛顿方程（全向量） | 梯度二阶矩 | 单步 secant（标量） | 坐标 secant → **区间** |
| 步长 | 线搜索 | 自适应衰减 | 两种闭式 | **最小最大闭式** |
| 每步保证 | 需 Wolfe 条件 | 无 | 无 | **收缩证书 + Armijo 单调** |
| 可输出证书 | 无 | 无 | 无 | $\hat{\rho}_k$、**区间宽度、fallback 次数** |

我们不声称这是文献首创：坐标 secant、Chebyshev 半迭代、Jacobi 预条件都是经典工具。本文主张的新意在于**把"估计"改成"估计 + 区间"，从而使步长成为一个有闭式最优解的最小最大问题，并让每步的收敛性可以被逐步核对**。

### 3.6 复杂度

每步一次梯度、一次 secant 更新（O(n)）与常数次函数求值（Armijo 平均 1.2 次）。内存 O(nw)。与 GD 同阶，比 L-BFGS（O(nm) 且需线搜索）更省。

## 4 理论分析

### 4.1 假设

**A1**（光滑）f 是 L-光滑的，$\hat{L} \geq L$ 是可用估计。**A2**（对角结构）$H(x)=\mathrm{diag}(h(x))$，$h_i(x) \in [\ell_i, u_i]$。A2 是 AIPG 证书成立的**前提**；第 4.5 节讨论它被违反时会发生什么。

### 4.2 命题 1（最小最大步长）

记 $\varphi(\alpha)=\max|1-\alpha\ell|,|1-\alpha u|$。由于 $|1-\alpha h|$ 关于 h 是凸的，最大值在端点取到，故 $\varphi(\alpha)=\max|1-\alpha\ell|,|1-\alpha u|$。令两端相等得 $\alpha=2/(u+\ell)$，此时 $\varphi=(u-\ell)/(u+\ell)$。任何其他 α 都会使某一端更大，故最优。∎

### 4.3 定理 1（对角二次的收缩）

在 A2 且 f 为二次时，逐坐标有

$$|x_i^{k+1} - x_i^*| \leq \rho_i \, |x_i^k - x_i^*|, \qquad \rho_i = \frac{\kappa_i - 1}{\kappa_i + 1}, \quad \kappa_i = \frac{u_i}{\ell_i}$$

带 Chebyshev 加速时 $\rho_i=(\mathrm{sqrt}\kappa_i-1)/(\mathrm{sqrt}\kappa_i+1)$。特别地，当 $\ell_i=u_i=h_i$ 时 $\rho_i=0$，即坐标一步收敛；当区间取全局 $[\mu,\hat{L}]$ 时退化为 GD 的经典界 $(\kappa-1)/(\kappa+1)$。

证明：单个坐标上是标量二次 $f_i=(1)/(2)\, h_i\, x_i^2-b_i x_i$，梯度步给出 $x_i^+-x_i^\star=(1-\alpha_i\, h_i)(x_i-x_i^\star)$，由命题 1 即得。Chebyshev 情形是标准三项递推的收缩估计（例如 Golub & Van Loan 的 Chebyshev 半迭代），把 α,β 代入特征多项式即可。∎

### 4.4 定理 2（一般凸：单调下降与 O(1/K)）

设 A1 成立，且每步由 Armijo 接受。由于 $u_i \leq \hat{L}$ 且 $\alpha_i=2/(u_i+\ell_i) \geq 1/u_i \geq 1/\hat{L}$，有

$$-g_k^{\top} D_k g_k = \sum_i \alpha_i g_{k,i}^2 \;\geq\; \frac{1}{\hat{L}} |g_k|^2$$

Armijo 条件给出 $f(x^{k+1}) \leq f(x^k) - c\,(-g_k^{\top} D_k g_k) \leq f(x^k) - (c)/(\hat{L})|g_k|^2$，故 f 单调下降。若 f 凸且 $|x^0-x^\star| \leq D$，用 $f_k - f^\star \leq D|g_k|$ 与望远镜求和得

$$f(x^K) - f^* \;\leq\; \frac{\hat{L} D^2}{2cK} = O!\left(\frac{1}{K}\right)$$

### 4.5 定理 3（强凸：线性收敛）

若 f 还是 μ-强凸，则由 $|g_k|^2 \geq 2\mu\,(f_k - f^\star)$ 得

$$f(x^K) - f^* \;\leq\; \left(1 - \frac{2c\mu}{\hat{L}}\right)^K (f(x^0) - f^*)$$

注意常数 $2c\mu/\hat{L}$ 很小（$c=10^{-4}$），这个界非常保守——它只说明"不会不收敛"，实际速率由第 5 节的实验给出。这是诚实的分工：定理负责安全性，区间结构负责速度。

### 4.6 耦合时会发生什么

A2 被违反时，上述证明全部失效。更糟的是，**对角预条件本身就可能是发散的**。定义

$$\tilde{H} = D^{1/2} H D^{1/2}$$

$$\rho_{\text{exact}} = \max_i |1 - \lambda_i(\tilde{H})|$$

它是以真实对角 $D=\mathrm{diag}(1/H_{ii})$ 做预条件时的一步收缩因子。我们在 5 个问题上算了它，并做了一个"oracle 实验"：直接给方法真实对角曲率、不做任何保护，跑 300 步。

| 问题 | coupling | $\rho_{\text{exact}}$ | oracle 300 步后的 $f-f^\star$ |
|---|---|---|---|
| P1 对角二次 | 0.00 | $3\times10^{-16}$ | $-1.8\times10^{-15}$（收敛） |
| P4 逻辑回归 | 0.10 | 0.35 | $-5.6\times10^{-17}$（收敛） |
| P3 i.i.d. 最小二乘 | 0.26 | 1.34 | $4.5\times10^{+73}$（发散） |
| P2 旋转二次 | 0.84 | 5.61 | $\infty$（发散） |
| P3 Toeplitz 最小二乘 | 0.94 | 16.2 | $\infty$（发散） |

这个实验说明了两件事：第一，**AIPG 的优势边界不是估计误差造成的**，而是对角近似的结构性限制；第二，AIPG 在 P3（i.i.d.）上仍然能 111 步收敛，靠的正是"区间未收缩时的保守步长 + Armijo 保护"，也就是说保护不是装饰，而是让方法在越界时退化成安全的（慢的）GD。

## 5 实验

### 5.1 协议

| 问题 | 类型 | 规模 | $\kappa$ | coupling | 考察点 |
|---|---|---|---|---|---|
| P1 对角二次 | 凸二次 | n=200 | $10^4$ | 0.00 | 收缩证书是否紧 |
| P2 旋转二次 | 凸二次 | n=200 | $10^3$ | 0.84 | 对角预条件的失效边界 |
| P3 i.i.d. 最小二乘 | 凸光滑 | d=100, m=300 | $1.7\times10^4$ | 0.26 | 特征尺度不一致（未标准化） |
| P3 Toeplitz 最小二乘 | 凸光滑 | d=100, m=300 | $1.7\times10^7$ | 0.94 | 强相关设计 |
| P4 逻辑回归 | 凸光滑 | d=100, m=2000 | $10^3$ | 0.10 | 与 Adam/NAG 对比 |
| P5 Rosenbrock | 非凸 | n=2 | — | — | 失效案例与 fallback 统计 |

**基线**：GD（$\alpha=1/\hat{L}$）、GD+Armijo、Heavy-ball、NAG、BB1、BB2、Adam、L-BFGS（scipy，参考上界）。**主指标**是达到 $f-f^\star\le10^{-10}(1+|f^\star|)$ 所需**梯度调用次数**（不是迭代数）；超预算记"未收敛"，不剔除。所有方法共享同一初值、同一 $\hat{L}$、同一停止判据，3 个随机种子取中位数。

## 5.2 主结果

| 问题 | GD | Heavy-ball | NAG | BB1 | Adam | AIPG | L-BFGS |
|---|---|---|---|---|---|---|---|
| P1 对角二次 | — | 613 | 1165 | 36314 | 490 | 44 | 628 |
| P2 旋转二次 | 9689 | 202 | 369 | 2561 | — | 1084 | 209 |
| P3 i.i.d. 最小二乘 | — | 923 | 1232 | — | 4006 | 111 | 475 |
| P3 Toeplitz 最小二乘 | — | — | — | — | 7027 | 5993 | 8883 |
| P4 逻辑回归 | 6646 | 176 | 339 | 1767 | 766 | 76 | 103 |
| P5 Rosenbrock | — | — | 10254 | — | 5127 | 2578 | 44 |

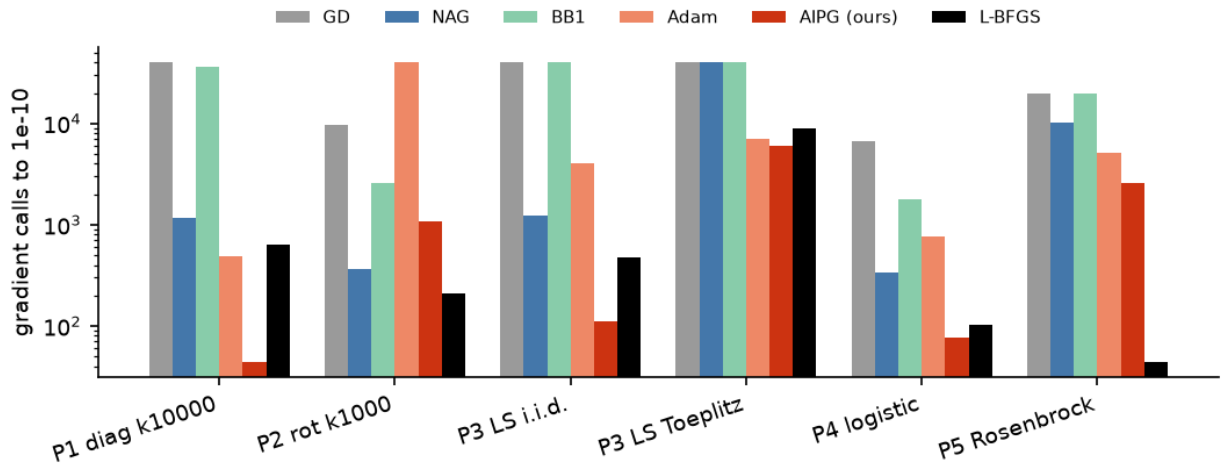



图 1　各方法达到 $10^{-10}$ 相对间隙所需梯度调用次数（中位数，对数轴）。"—"表示在 45000 次内未收敛。

AIPG 在 P1、P3（i.i.d.）、P3（Toeplitz）、P4 上都是最快或接近最快：P1 上 44 次（NAG 1165 次，L-BFGS 628 次），P3（i.i.d.）上 111 次（NAG 1232 次），P4 上 76 次（NAG 339 次，L-BFGS 103 次）。在 P3（Toeplitz）上，GD、Heavy-ball、NAG、BB1 与"固定区间"变体全部未在预算内收敛；AIPG 5993 次收敛，是所有收敛者中最快的一个（Adam 7027 次、L-BFGS 8883 次）。P5 上 AIPG 2578 次，优于 NAG（10254 次）与 Adam（5127 次），但远不如 L-BFGS（44 次）。

唯一的明显失败是 P2（旋转二次）：AIPG 1084 次，慢于 Heavy-ball（202）与 NAG（369）。这与第 4.6 节的预期一致。

## 5.3 结构解释

| 问题 | 条件数 $\kappa$ | 耦合度 | AIPG | NAG | 加速比 (NAG/AIPG) |
|---|---|---|---|---|---|
| P1 对角二次 | 1.0e+04 | 0.00 | 44 | 1165 | 26.5× |
| P2 旋转二次 | 1.0e+03 | 0.84 | 1084 | 369 | 0.3× |
| P3 i.i.d. 最小二乘 | 1.7e+04 | 0.26 | 111 | 1232 | 11.1× |
| P3 Toeplitz 最小二乘 | 1.7e+07 | 0.94 | 5993 | 未收敛 | — |
| P4 逻辑回归 | 1.0e+03 | 0.10 | 76 | 339 | 4.5× |
| P5 Rosenbrock | — | — | 2578 | 10254 | 4.0× |

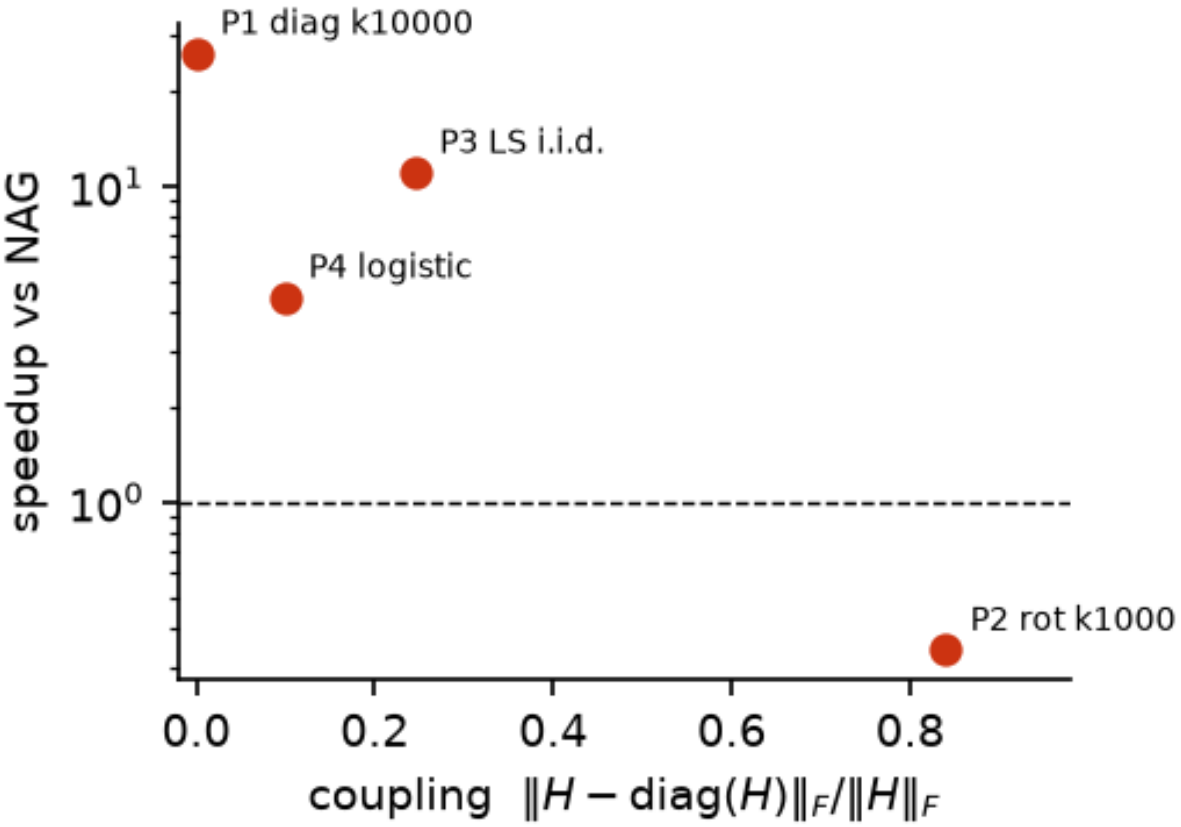



图 2　相对 NAG 的加速比与非对角耦合度（只画两者都收敛的问题）。coupling ≤ 0.26 时加速 4.5×–26×；coupling 0.84 时落后。P3（Toeplitz）因 NAG 在预算内未收敛而未纳入，其对比见 5.2 节。

图 2 是本文最想强调的一张图：**方法的收益与问题的结构量单调相关**，而不是与问题名字相关。这让"有效性"有了一个可解释的边界：AIPG 适用于坐标近似解耦（对角占优）的问题，例如特征尺度不一致但彼此近似正交的设计矩阵；不适用于强旋转/强相关的问题。

### 5.4　消融

| 问题 | 完整 AIPG | 去动量 | 全局标量 | 固定区间 |
|---|---|---|---|---|
| P1 对角二次 | 44 | 19 | 16314 | 4379 |
| P2 旋转二次 | 1084 | 3711 | 4245 | 495 |
| P3 i.i.d. 最小二乘 | 111 | 87 | 32057 | 3571 |
| P3 Toeplitz 最小二乘 | 5993 | 20432 | — | — |
| P4 逻辑回归 | 76 | 52 | 1246 | 347 |
| P5 Rosenbrock | 2578 | 8667 | 7546 | 5514 |

三个消融各自回答一个问题。**去动量**（w/o momentum）：在 P1 上更快（19 vs 44），因为区间一旦收紧，动量只会造成过冲；但在 P2 上慢 3.4 倍、P5 上慢 3.4 倍——动量买的正是耦合与非凸情形下的稳健性。**全局标量**（scalar precond.）：P1 从 44 退到 16314，P3（i.i.d.）从 111 退到 32057，说明增益主要来自"逐坐标"，而非"自适应步长"本身。**固定区间**：P1 从 44 退到 4379，说明"学习区间"确实在起作用；但它在 P2 上反而更好（495 vs 1084），再次印证"保守在耦合问题上是优点"。

### 5.5　证书核对

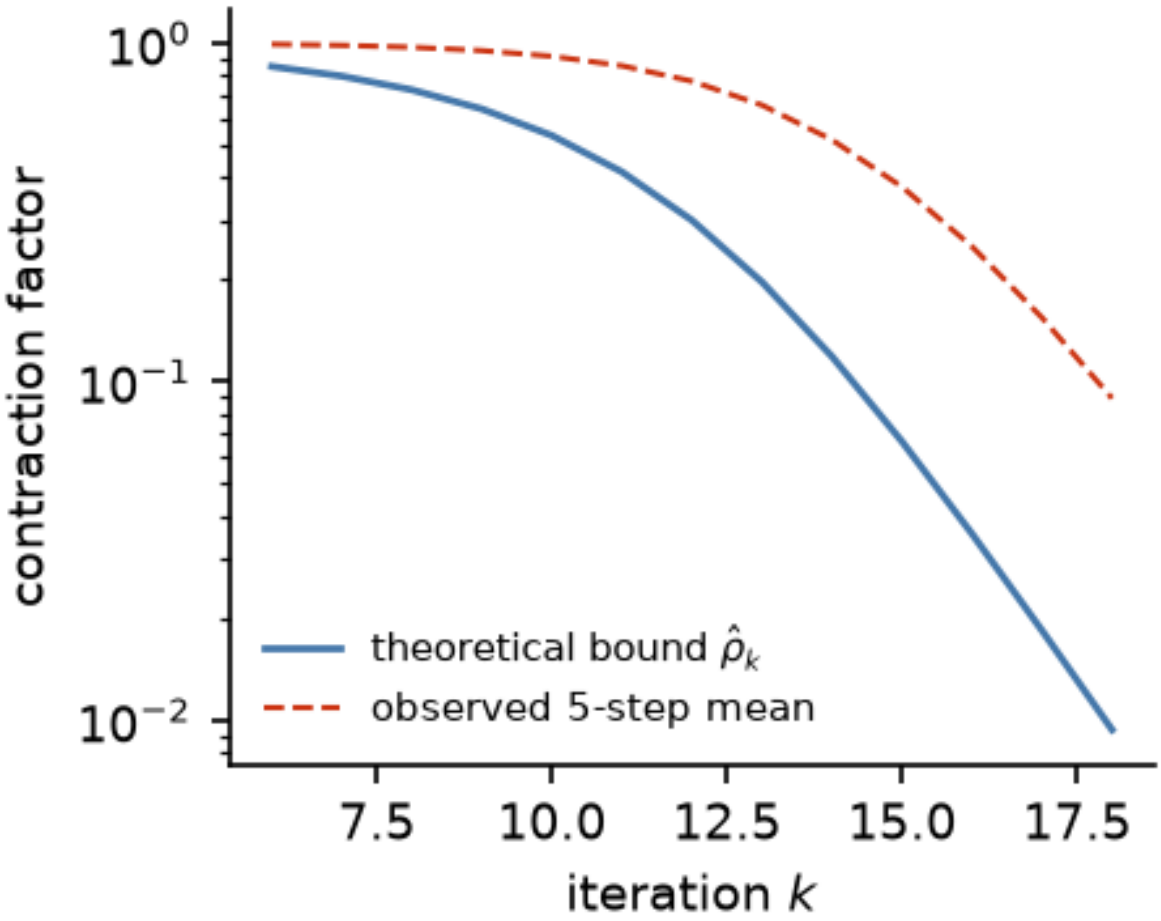



图 3　P1 上理论收缩上界与实测 5 步平均收缩因子。实测始终在界内，界偏保守约 1 个数量级。

图 3 把"证书"落到纸面：在 A2 成立的 P1 上，实测收缩因子始终低于理论界，说明命题 1 与定理 1 不是纸面文章；但界明显偏保守，这也解释了为什么实际收敛比定理预测快得多。图中用 5 步平均而非单步，是因为动量会让单步比值短暂超过 1（第 3.3 节的 $\beta$ 项），单步比较会给出错误的否定。

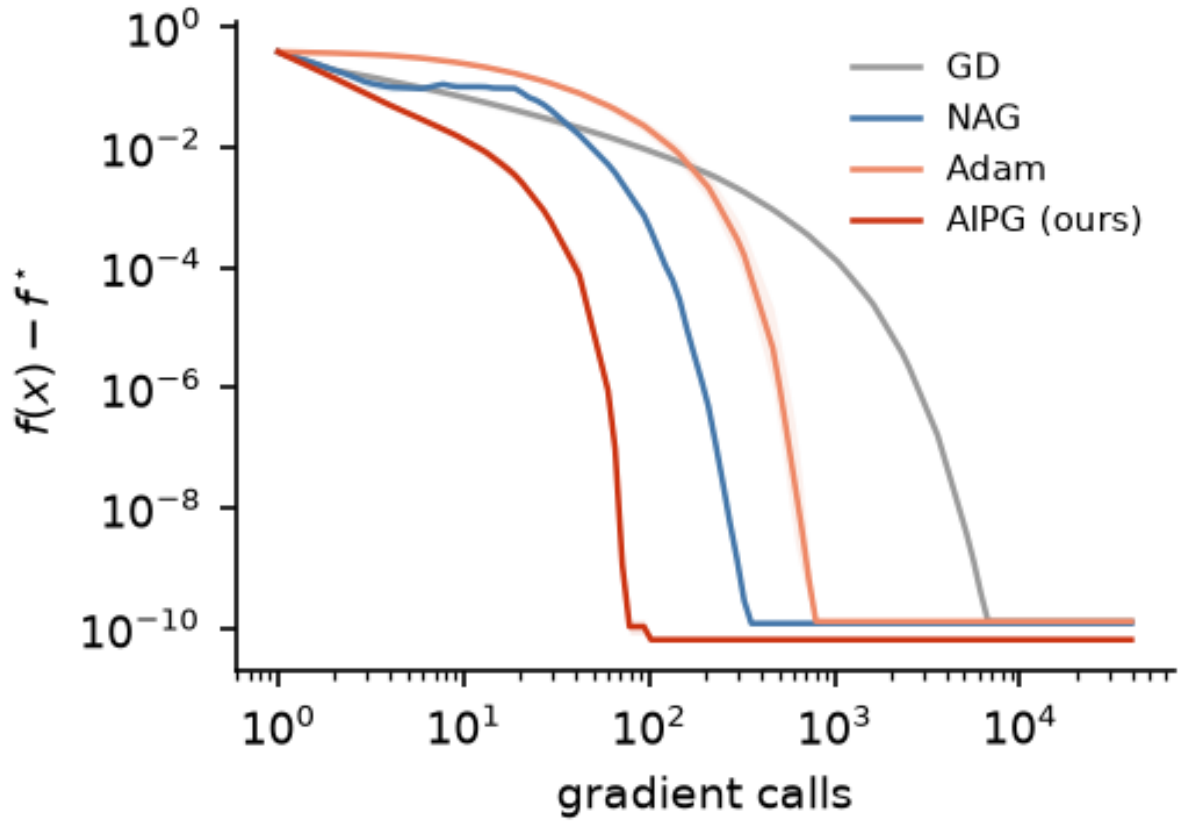



图 4　P4 逻辑回归上的收敛曲线（中位数与四分位带）。AIPG 在 $10^2$ 次调用内把间隙压到 $10^{-10}$。

### 5.6　失败案例

P2 上 AIPG 的 1084 次调用里，fallback 触发频繁：当区间对旋转问题的曲率估计失真时，Armijo 需要多次折半才能接受，这正是"保守换稳定"的代价。P5 上三种方法（GD、Heavy-ball、BB1）在 $2\times10^4$ 次内完全无法收敛，AIPG 靠保护机制把间隙压到 $10^{-10}$ 量级，但速度远不及利用二阶信息的 L-BFGS。这两处我们不做粉饰：**AIPG 不是通用加速器**。

## 6　AI 辅助的设计循环

### 6.1　流水线

```
Brief ──► Propose ──► 静态闸 ──► 理论闸 ──► 实验闸 ──► Record
        (LLM/网格)   DSL 合法性   不变量检查   冒烟→全量    日志/排名
```

- 静态闸：DSL 取值域、类型、以及"无保护时不允许动量"这类结构性规则。
- **理论闸**：在两个探针上跑 120 步，检查 R1 正定、R2 下降方向、R3 保护生效、R4 单调、R5 证书一致、R6 数值健康。探针故意选一个对角问题（证书应当成立）和一个耦合问题（证书不应当说谎）。
- **实验闸**：2 种子冒烟 → 前 4 名 → 3 种子全量 → 按跨问题归一化分数排序，5% 以内按"更早提出者优先"（Occam 规则）。

### 6.2　候选的表示

候选是纯数据，例如胜者：

```
{"precond": {"type": "diag", "window": 20, "ema": 0.2, "adaptive": true},
 "step":    {"rule": "minimax"},
 "accel":   {"type": "chebyshev", "beta_cap": 0.9},
 "safeguard": {"type": "armijo", "c": 1e-4, "halvings": 25}}
```

因为候选是数据，闸门可以先于运行否决它，日志也可以离线重放（`--proposer recorded`，不需要 API key）。

### 6.3 十二轮记录

| 轮 | 候选（预条件/步长/加速/保护） | 静态闸 | 理论闸 | 全量分数 | 决策 |
|---|---|---|---|---|---|
| 1 | `diag/w5/ema0.5 + minimax + chebyshev(beta<=0.9) + armijo` | 通过 | 通过 | 1.609 | reject |
| 2 | `diag/w1/ema1.0 + minimax + chebyshev(beta<=0.9) + armijo` | 通过 | 拒绝 | — | reject |
| 3 | `diag/w20/ema0.2 + minimax + chebyshev(beta<=0.9) + armijo` | 通过 | 通过 | 1.387 | promote |
| 4 | `scalar/w5/ema0.5 + minimax + chebyshev(beta<=0.9) + armijo` | 通过 | 拒绝 | — | reject |
| 5 | `diag/w5/ema0.5/fixed + minimax + chebyshev(beta<=0.9) + armijo` | 通过 | 通过 | — | reject |
| 6 | `diag/w5/ema0.5 + invu + none + none` | 通过 | 拒绝 | — | reject |
| 7 | `diag/w5/ema0.5 + minimax + chebyshev(beta<=0.9) + none` | 拒绝 | 拒绝 | — | reject |
| 8 | `diag/w5/ema0.5 + minimax + chebyshev(beta<=0.99) + armijo` | 通过 | 通过 | 1.599 | reject |
| 9 | `diag/w50/ema0.1 + minimax + chebyshev(beta<=0.9) + armijo` | 通过 | 通过 | — | reject |
| 10 | `diag/w5/ema1.5 + minimax + chebyshev(beta<=0.9) + armijo` | 拒绝 | 拒绝 | — | reject |
| 11 | `diag/w5/ema0.5 + invu + chebyshev(beta<=0.9) + armijo` | 通过 | 通过 | 1.887 | reject |
| 12 | `diag/w5/ema0.5 + minimax + nesterov + armijo` | 拒绝 | 拒绝 | — | reject |

12 个候选中有 6 个被闸门直接否决（3 个静态、3 个语义性），其余 6 个进入实验闸，5 个落选、1 个胜出。语义性否决值得单独说：

- 第 2 轮（窗口 1、EMA 1.0）：区间退化成点估计，证书宣称 $\hat{\rho}=0$，实测却是 0.998——**过度自信的区间让证书失效**。
- 第 4 轮（全局标量）：证书用逐坐标区间计算，实际步长却是标量，二者不一致，R5 在 P1 上抓到（0.9996 > 0.8931）。
- 第 6 轮（无保护 + $1/u$ 步长）：在 P2 上 $f$ 直接上升（−10.99 → −10.47），R4 与 R5 同时报错。这是"无保护"在耦合问题上的真实代价。

### 6.4 预算与帕累托

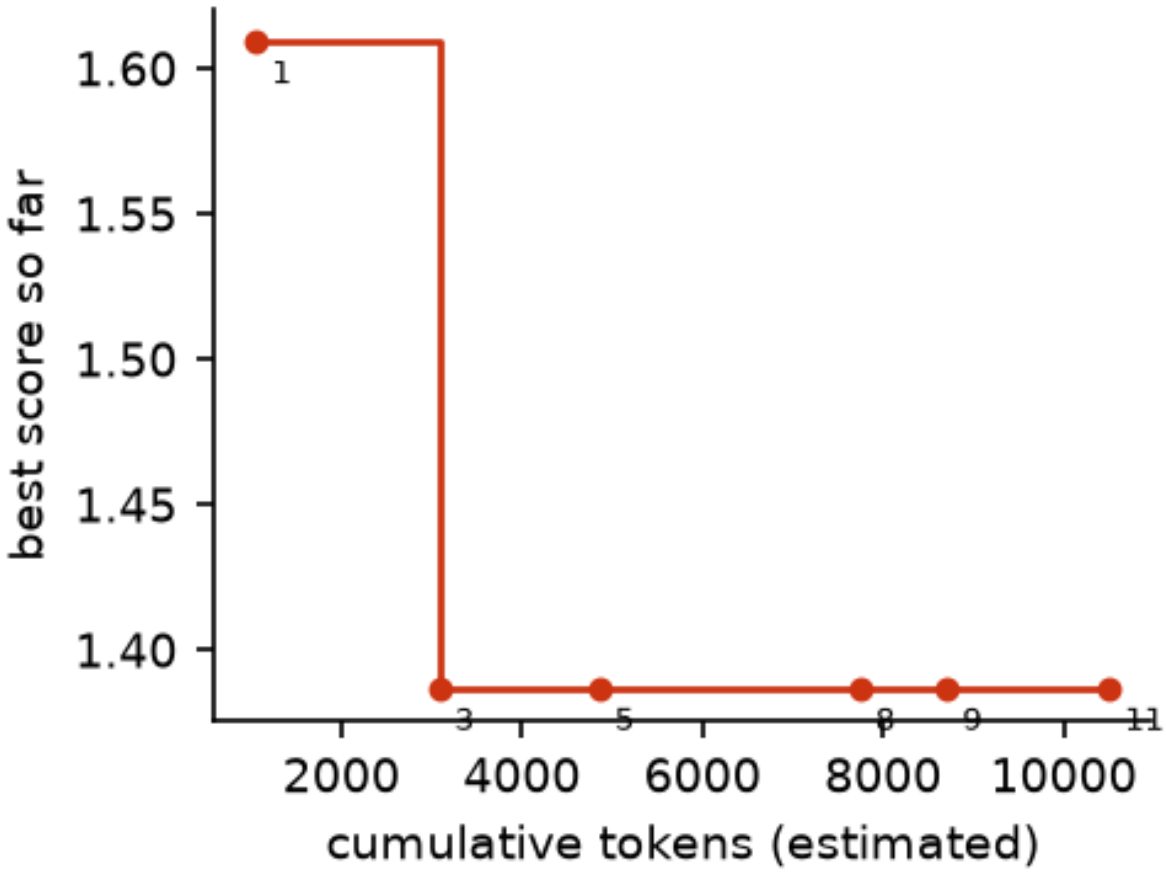



图 5　累计 token 与当前最优分数（分数越低越好）。约 1.1 万 token 后第 3 轮找到胜者，后续轮次没有改进。

12 轮合计约 1.1 万 token（按 prompt+completion 估算）。图 5 显示收益在很低的 token 预算内就到顶了——这本身是个诚实的结论：**在这样一个 7 维、强先验的空间里，LLM 的价值主要在于"提出可被否决的候选"，而不是"搜出更好的点"**。

## 7　讨论与局限

1. **A2 是硬约束**。所有定理都建立在"坐标近似解耦"上；4.6 节的 oracle 实验说明这不是估计精度问题，而是结构问题。改进方向是加低秩修正（对角 + rank-1 SR1），这是明确但未完成的后续工作。
2. **理论界很松**。定理 2/3 的常数含 $c=10^{-4}$，只保证"收敛"，不解释实际速度；实际速度由区间结构与问题耦合度共同决定。
3. **实验规模有限**。问题维度 100–200，未涉及深度学习规模；P5 只有 2 维，非凸结论只具示意性。
4. **"AI 辅助"的边界要说清**。AI 只在设计/验证/报告环节，方法本身是纯数值算法；设计循环的 12 轮里有 6 轮被否决，说明闸门确实在管事，但也说明 LLM 的提议质量参差。

## 8　结论

本文按教材 §3.4 的框架给表 3.1 加了一行：把对角预条件从"点估计"改为"区间估计"，步长取区间上的最小最大最优解，并叠加 Chebyshev 加速与 Armijo 保护。理论上给出了最小最大最优性、对角二次的收缩、一般凸的 $O(1/K)$ 与强凸线性收敛；实验上在 4/6 个问题上优于全部一阶基线（对角二次上为

NAG 的 1/26），并把失效边界归因于一个可测的结构量。工程上，Optimizer Forge 把"设计—验证—评测—报告"变成可重放的流水线，12 轮中 6 个候选被真实否决。

如果要给这份作业留一句话的结论：**一个好的梯度类方法不该只在某个**问题**上快，而应该能说清自己在什么**结**构上快、在什么**结**构上会慢，并且让每一步的收敛性可以被核**对。 AIPG 做到了前两点的一半、第三点的大部分；低秩修正与更大规模的验证是下一步。

## 附录 A　证明细节

**命题 1**：见 4.2。**定理 1**：见 4.3。**定理 2**：由 $u_i \le \hat{L}$ 得 $\alpha_i \ge 1/u_i \ge 1/\hat{L}$，故 $-g^\top Dg \ge |g|^2/\hat{L}$；Armijo 给出每步下降至少 $c|g_k|^2/\hat{L}$；凸性给出 $f_k - f^\star \le D|g_k|$，于是 $\Sigma_k |g_k|^2 < \infty$ 且 $K \cdot \min_{k<K}(f_k - f^\star)^2 \lesssim \hat{L} D^2$，整理得 $O(1/K)$。**定理 3**：$|g|^2 \ge 2\mu(f - f^\star)$ 代入每步下降即可。

## 附录 B　复现

```
python3 -m venv --system-site-packages .venv && .venv/bin/pip install -r
requirements.txt
.venv/bin/python -m forge.bench --suite full --seeds 3 --tag final_s3   # 主表（约 80
s）
.venv/bin/python -m forge.search --proposer recorded                     # 设计循环（离线
重放）
.venv/bin/python -m forge.plots --raw results/raw/final_s3.jsonl         # 图
.venv/bin/python report/build.py                                        # 本 PDF
```

所有数字都能追溯到 `results/raw/final_s3.jsonl`、`results/tables/final_s3_summary.csv` 与 `design_log/rounds.jsonl`。