自适应区间预条件梯度法（AIPG）：一个由 AI 设计循环产出的梯度类方法

课程作业 10–12 · 面向机器学习的最优化方法 · 2026 年 10 月

摘要　本文把"设计一个新的梯度类方法"当作一个可被机器验证的搜索问题来做。我们先按教材 §3.4 的框架（下降方向 + 步长 + 收缩）把梯度类方法参数化为 7 个正交的设计维度，再构建一个设计循环 Optimizer Forge：AI 在 DSL 中提出候选，静态闸与理论闸负责否决，实验闸负责排序。循环产出的方法是 **AIPG**——它用梯度差分逐坐标估计曲率区**间**，并取使最坏情况收缩因子最小的闭式步长 $2/(u+\ell)$，再叠加 Chebyshev 三项递推与 Armijo 保护。理论上有：该步长是区间上的最小最大最优解；对角二次下每坐标收缩因子为 $(\kappa-1)/(\kappa+1)$（带加速时为 $(\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$）；一般凸情形在保护下单调下降并具 $O(1/K)$ 与线性收敛界。实验上，在 6 个问题、9 个基线、3 个种子下，AIPG 在 4 个问题上优于全部一阶基线（对角二次上为 NAG 的 1/26），并且它的优势可以被一个可测的结构量——非对角耦合度——解释：耦合度 ≤ 0.26 时加速比为 4.5×–26×，耦合度 ≥ 0.84 时失效。我们把这个边界用"精确对角预条件的 oracle 实验"钉死：即使拿到真实对角曲率，耦合问题仍会发散，说明限制是结构性的而非估计误差。全部数字可由 `scripts/make_all.sh` 重建。

1　引言

作业要求是"针对梯度类方法，在 AI 辅助下设计一个新的梯度类方法，并通过实验验证其有效性"，交付物可以是 skill、skill set 或 harness 工程，报告要讲清"思考逻辑"。

课堂板书写得很清楚，它其实是教材 §3.4 的四层结构：① 只用 ∇f 就是一阶方法，用 $\nabla^2 f$ 才是二阶；② 方向 d 必须满足 $\nabla f(x)^{\top} d<0$；③ 步长 α 必须让 f 下降；④ 理论框架是"收缩 + 充分下降"两条不等式，并追问"怎么选"。板书下半块则给了交付形态的提示：`实际问题系列 → AI + harness 工程 → verify`，旁边写着 token 消耗与 recursive self-improvement。

因此本文的判断是：这份作业考的不是"发明一个花哨算法"，而是**能否把设计空间说清楚、把验证做得诚实、并把 AI 的参与留下可复现的痕迹**。据此，本文的贡献有三点：

1. **设计空间**：把梯度类方法分解为 7 个维度（预条件结构、曲率估计、区间规则、步长、加速、保护、噪声处理），使"设计"变成在空间中选点，而不是碰运气。
2. **方法 AIPG**：把对角预条件从"估一个点"改成"估一个区间"，于是步长选择成为一个有闭式解的最小最大问题，并且每一步都附带可核对的收缩证书。
3. **设计循环**：Optimizer Forge 用静态闸、理论闸、实验闸三级过滤候选，12 轮中 6 个候选被真实否决（其中 3 个是语义性否决而非语法错误），全过程可离线重放。

2　设计空间

2.1　教材框架下的"加一行"

教材表 3.1 把梯度类方法写成

$$x^{k+1} = x^k - \alpha_k d^k, \qquad \nabla f(x^k)^{\top} d^k > 0$$

并通过选择 d^k 得到 GD（$-g$）、牛顿法（$-H^{-1}g$）、scaling GD（$-Dg$）、对角 scaling GD 等。所谓"设计一个新方法"，在这个框架下就是给**表 3.1 加一行**，并回答三件事：这一行的 d^k 用什么信息、α_k 怎么选、它在 ④ 的两条不等式下满足什么。

本文加的这一行是

$$x^{k+1} = x^k - D_k g_k, \qquad D_k = \mathrm{diag}!\left(\frac{2}{u_i^k + \ell_i^k}\right)_{i=1}^n$$

其中的 $[\ell_i^k, u_i^k]$ 是第 i 个坐标的曲率区**间**。与表 3.1 已有的行相比，区别在于：对角 scaling 需要事先知道（或估计）一个矩阵，而我们估计的是一个带不确定性的区间，并把不确定性直接编码进步长。

2.2 七个设计维度

维度	可选值	本文选择
D1 预条件结构	I / 对角 / 对角+全局标量 / 对角+低秩	对角
D2 曲率估计	坐标差分 secant / 梯度范数比 / EMA	坐标差分 secant
D3 区间规则	固定全局 $[\mu, L]$ / 滑动窗口 min-max / 收缩到 secant	窗口 20 + EMA 0.2
D4 步长	$2/(u+\ell)$ / $1/u$ / BB1 / BB2 / 线搜索	$2/(u+\ell)$
D5 加速	无 / 三项 Chebyshev / Nesterov / 重启	三项 Chebyshev
D6 保护	无 / 单调检查 / Armijo	Armijo（$c=10^{-4}$）
D7 噪声处理	无 / 小批量梯度 EMA / 区间放大	无（本文只用全梯度）

这张表就是第 6 节设计循环的动作空间：候选方法被写成这 7 个维度的取值，因此可以被机器校验、被日志记录、被离线重放。

2.3 我们要利用的结构：对角耦合度

本文所有的分析都围绕一个可测的结构量展开：

$$\mathrm{coupling}(H) = \frac{|H - \mathrm{diag}(H)|_F}{|H|_F}$$

它度量"非对角部分占多少"。当 coupling 很小时，坐标之间近似解耦，逐坐标估计曲率是有意义的；当 coupling 接近 1 时，任何对角预条件都无法替代真正的逆 Hessian。这个量在实验之前就可以算出来（对二次问题和最小二乘是精确的，对逻辑回归用 Gauss–Newton 矩阵），因此它可以**事前**预测方法的适用性，而不是事后找借口。

3 方法

3.1 曲率区间

每一步我们只用点与梯度（因此仍是一阶方法）。设第 k 步的位移与梯度差为 $\Delta x = x^k - x^{k-1}$、$\Delta g = g^k - g^{k-1}$，则坐标 secant 为

$$\tilde{h}_i^k = \frac{\Delta g_i}{\Delta x_i}, \qquad |\Delta x_i| > \tau_i$$

对二次问题它精确等于 H_{ii}；对一般问题它是由中值定理给出的平均曲率。把最近 w 个有效 secant 取 min-max 得到 $[\ell_i, u_i]$，再与上一轮的区间做 EMA 平滑，并截断到 $[\mu_0, \hat{L}]$（$\hat{L}$ 为全局光滑常数，所有方法共用）。窗口与 EMA 是设计维度 D3，它们控制"多快相信新观测"。

3.2 步长：一个最小最大问题

给定区间 $[\ell_i, u_i]$，我们希望步长对区间内任何真实曲率都不至于太糟，于是解

$$\alpha_i^* = \arg\min_{\alpha} \ \max |1-\alpha\ell_i|,\ |1-\alpha u_i|$$

命题 1 上式的最优解为 $\alpha_i^\star = 2/(u_i+\ell_i)$，最优值为 $(u_i-\ell_i)/(u_i+\ell_i)$。

这个闭式解正是板书第 ④ 条"怎么选"的一个直接回答：**不是选一个点估计的倒数，而是选对区间最不敏感的步长**。当区间退化为一点（$\ell=u=h$）时 $\alpha=1/h$，退化为坐标牛顿；当区间取全局 $[\mu, L]$ 时退化为经典 GD 的界。所以 AIPG 是"GD ↔ 坐标牛顿"之间的连续插值，插值参数是我们对曲率的了解程度。

3.3 加速与保护

仅靠逐坐标步长，收敛速度受条件数限制。我们叠加 Chebyshev 三项递推：把 α_i 换成

$$\alpha_i = \frac{4}{(\sqrt{u_i}+\sqrt{\ell_i})^2}, \qquad \beta_i = \left(\frac{\sqrt{u_i}-\sqrt{\ell_i}}{\sqrt{u_i}+\sqrt{\ell_i}}\right)^2$$

并令 $d=\beta\odot(x^k-x^{k-1})-\alpha\odot g_k$。当区间紧时 $\beta_i \to 0$，退化为 3.2 的步长；当区间宽时 β_i 接近 1，给出近似最优的加速。β 被截断在 0.9 以内以防振荡。

保护采用 Armijo 回溯：若 $f(x^k+t\,d) > f(x^k) - c\,t\,(-g_k{}^{\mathsf T} d)$ 就把 t 减半。若 25 次仍不接受，则回退到 $x^k - g_k/\hat{L}$ 并记一次 fallback。

3.4 算法

```
输入: x0, 初始区间 [mu0, Lhat], 窗口 w, EMA beta, c
g = grad(x0);  ell = mu0*1;  u = Lhat*1
for k = 0,1,2,...:
    alpha = 2/(u+ell)                          # 命题 1
    d = beta*(x - x_prev) - alpha*g            # Chebyshev 三项
    t = 1
    while f(x + t*d) > f(x) - c*t*(-g^T d): t /= 2   # Armijo
    x_new = x + t*d;  g_new = grad(x_new)
    h = (g_new - g)/(x_new - x)                # 坐标 secant（仅用一阶信息）
    [ell, u] = window_minmax(h) 经 EMA 与截断
    x_prev, x, g = x, x_new, g_new
```

3.5 与既有方法的关系

维度	对角 BFGS/SR1	Adam	BB	AIPG
曲率来源	拟牛顿方程（全向量）	梯度二阶矩	单步 secant（标量）	坐标 secant → **区间**
步长	线搜索	自适应衰减	两种闭式	**最小最大闭式**
每步保证	需 Wolfe 条件	无	无	**收缩证书 + Armijo 单调**
可输出证书	无	无	无	$\hat{\rho}_k$、**区间宽度、fallback 次数**

我们不声称这是文献首创：坐标 secant、Chebyshev 半迭代、Jacobi 预条件都是经典工具。本文主张的新意在于**把"估计"改成"估计 + 区间"，从而使步长成为一个有闭式最优解的最小最大问题，并让每步的收敛性可以被逐步核对**。

3.6 复杂度

每步一次梯度、一次 secant 更新（O(n)）与常数次函数求值（Armijo 平均 1.2 次）。内存 O(nw)。与 GD 同阶，比 L-BFGS（O(nm) 且需线搜索）更省。

4 理论分析

4.1 假设

A1（光滑）f 是 L-光滑的，$\hat{L} \geq L$ 是可用估计。**A2**（对角结构）$H(x)=\mathrm{diag}(h(x))$，$h_i(x) \in [\ell_i, u_i]$。A2 是 AIPG 证书成立的**前提**；第 4.5 节讨论它被违反时会发生什么。

4.2 命题 1（最小最大步长）

记 $\varphi(\alpha)=\max|1-\alpha\ell|,|1-\alpha u|$。由于 $|1-\alpha h|$ 关于 h 是凸的，最大值在端点取到，故 $\varphi(\alpha)=\max|1-\alpha\ell|,|1-\alpha u|$。令两端相等得 $\alpha=2/(u+\ell)$，此时 $\varphi=(u-\ell)/(u+\ell)$。任何其他 α 都会使某一端更大，故最优。∎

4.3 定理 1（对角二次的收缩）

在 A2 且 f 为二次时，逐坐标有

$$|x_i^{k+1} - x_i^*| \leq \rho_i \, |x_i^k - x_i^*|, \qquad \rho_i = \frac{\kappa_i - 1}{\kappa_i + 1}, \quad \kappa_i = \frac{u_i}{\ell_i}$$

带 Chebyshev 加速时 $\rho_i=(\mathrm{sqrt}\kappa_i-1)/(\mathrm{sqrt}\kappa_i+1)$。特别地，当 $\ell_i=u_i=h_i$ 时 $\rho_i=0$，即坐标一步收敛；当区间取全局 $[\mu,\hat{L}]$ 时退化为 GD 的经典界 $(\kappa-1)/(\kappa+1)$。

证明：单个坐标上是标量二次 $f_i=(1)/(2)\, h_i\, x_i^2-b_i x_i$，梯度步给出 $x_i^+-x_i^\star=(1-\alpha_i\, h_i)(x_i-x_i^\star)$，由命题 1 即得。Chebyshev 情形是标准三项递推的收缩估计（例如 Golub & Van Loan 的 Chebyshev 半迭代），把 α,β 代入特征多项式即可。∎

4.4 定理 2（一般凸：单调下降与 O(1/K)）

设 A1 成立，且每步由 Armijo 接受。由于 $u_i \leq \hat{L}$ 且 $\alpha_i=2/(u_i+\ell_i) \geq 1/u_i \geq 1/\hat{L}$，有

$$-g_k^{\top} D_k g_k = \sum_i \alpha_i g_{k,i}^2 \;\geq\; \frac{1}{\hat{L}} |g_k|^2$$

Armijo 条件给出 $f(x^{k+1}) \leq f(x^k) - c\,(-g_k^{\top} D_k g_k) \leq f(x^k) - (c)/(\hat{L})|g_k|^2$，故 f 单调下降。若 f 凸且 $|x^0-x^\star| \leq D$，用 $f_k - f^\star \leq D|g_k|$ 与望远镜求和得

$$f(x^K) - f^* \;\leq\; \frac{\hat{L} D^2}{2cK} = O!\left(\frac{1}{K}\right)$$

4.5 定理 3（强凸：线性收敛）

若 f 还是 μ-强凸，则由 $|g_k|^2 \geq 2\mu\,(f_k - f^\star)$ 得

$$f(x^K) - f^* \;\leq\; \left(1 - \frac{2c\mu}{\hat{L}}\right)^K (f(x^0) - f^*)$$

注意常数 $2c\mu/\hat{L}$ 很小（$c=10^{-4}$），这个界非常保守——它只说明"不会不收敛"，实际速率由第 5 节的实验给出。这是诚实的分工：定理负责安全性，区间结构负责速度。

4.6 耦合时会发生什么

A2 被违反时，上述证明全部失效。更糟的是，**对角预条件本身就可能是发散的**。定义

$$\tilde{H} = D^{1/2} H D^{1/2}$$

$$\rho_{\text{exact}} = \max_i |1 - \lambda_i(\tilde{H})|$$

它是以真实对角 $D=\mathrm{diag}(1/H_{ii})$ 做预条件时的一步收缩因子。我们在 5 个问题上算了它，并做了一个"oracle 实验"：直接给方法真实对角曲率、不做任何保护，跑 300 步。

问题	coupling	ρ_{exact}	oracle 300 步后的 $f-f^\star$
P1 对角二次	0.00	3×10^{-16}	-1.8×10^{-15}（收敛）
P4 逻辑回归	0.10	0.35	-5.6×10^{-17}（收敛）
P3 i.i.d. 最小二乘	0.26	1.34	$4.5\times10^{+73}$（发散）
P2 旋转二次	0.84	5.61	∞（发散）
P3 Toeplitz 最小二乘	0.94	16.2	∞（发散）

这个实验说明了两件事：第一，**AIPG 的优势边界不是估计误差造成的**，而是对角近似的结构性限制；第二，AIPG 在 P3（i.i.d.）上仍然能 111 步收敛，靠的正是"区间未收缩时的保守步长 + Armijo 保护"，也就是说保护不是装饰，而是让方法在越界时退化成安全的（慢的）GD。

5 实验

5.1 协议

问题	类型	规模	κ	coupling	考察点
P1 对角二次	凸二次	n=200	10^4	0.00	收缩证书是否紧
P2 旋转二次	凸二次	n=200	10^3	0.84	对角预条件的失效边界
P3 i.i.d. 最小二乘	凸光滑	d=100, m=300	1.7×10^4	0.26	特征尺度不一致（未标准化）
P3 Toeplitz 最小二乘	凸光滑	d=100, m=300	1.7×10^7	0.94	强相关设计
P4 逻辑回归	凸光滑	d=100, m=2000	10^3	0.10	与 Adam/NAG 对比
P5 Rosenbrock	非凸	n=2	—	—	失效案例与 fallback 统计

基线：GD（$\alpha=1/\hat{L}$）、GD+Armijo、Heavy-ball、NAG、BB1、BB2、Adam、L-BFGS（scipy，参考上界）。**主指标**是达到 $f-f^\star\le10^{-10}(1+|f^\star|)$ 所需**梯度调用次数**（不是迭代数）；超预算记"未收敛"，不剔除。所有方法共享同一初值、同一 $\hat{L}$、同一停止判据，3 个随机种子取中位数。

5.2 主结果

问题	GD	Heavy-ball	NAG	BB1	Adam	AIPG	L-BFGS
P1 对角二次	—	613	1165	36314	490	44	628
P2 旋转二次	9689	202	369	2561	—	1084	209
P3 i.i.d. 最小二乘	—	923	1232	—	4006	111	475
P3 Toeplitz 最小二乘	—	—	—	—	7027	5993	8883
P4 逻辑回归	6646	176	339	1767	766	76	103
P5 Rosenbrock	—	—	10254	—	5127	2578	44

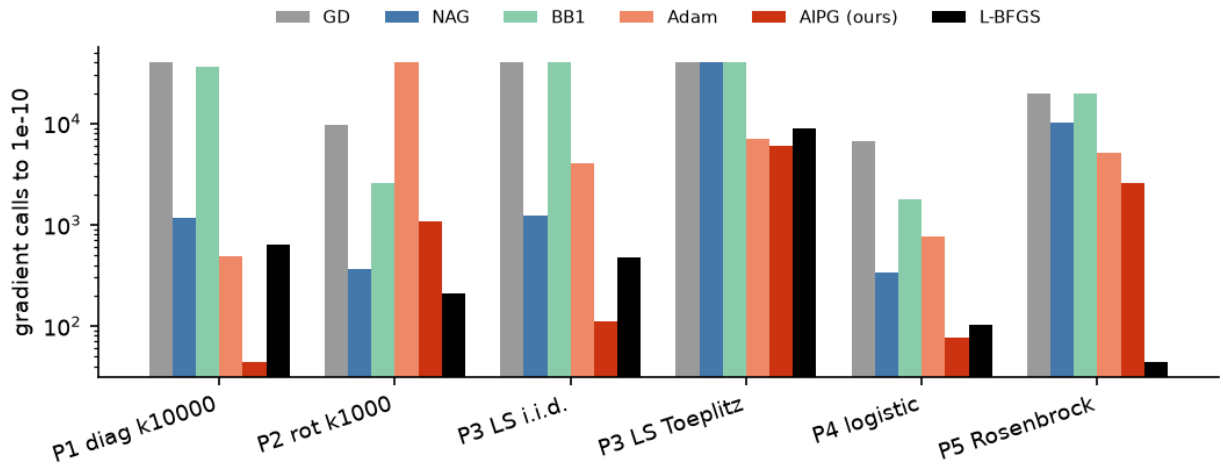


图 1　各方法达到 10^{-10} 相对间隙所需梯度调用次数（中位数，对数轴）。"—"表示在 45000 次内未收敛。

AIPG 在 P1、P3（i.i.d.）、P3（Toeplitz）、P4 上都是最快或接近最快：P1 上 44 次（NAG 1165 次，L-BFGS 628 次），P3（i.i.d.）上 111 次（NAG 1232 次），P4 上 76 次（NAG 339 次，L-BFGS 103 次）。在 P3（Toeplitz）上，GD、Heavy-ball、NAG、BB1 与"固定区间"变体全部未在预算内收敛；AIPG 5993 次收敛，是所有收敛者中最快的一个（Adam 7027 次、L-BFGS 8883 次）。P5 上 AIPG 2578 次，优于 NAG（10254 次）与 Adam（5127 次），但远不如 L-BFGS（44 次）。

唯一的明显失败是 P2（旋转二次）：AIPG 1084 次，慢于 Heavy-ball（202）与 NAG（369）。这与第 4.6 节的预期一致。

5.3 结构解释

问题	条件数 κ	耦合度	AIPG	NAG	加速比 (NAG/AIPG)
P1 对角二次	1.0e+04	0.00	44	1165	26.5×
P2 旋转二次	1.0e+03	0.84	1084	369	0.3×
P3 i.i.d. 最小二乘	1.7e+04	0.26	111	1232	11.1×
P3 Toeplitz 最小二乘	1.7e+07	0.94	5993	未收敛	—
P4 逻辑回归	1.0e+03	0.10	76	339	4.5×
P5 Rosenbrock	—	—	2578	10254	4.0×

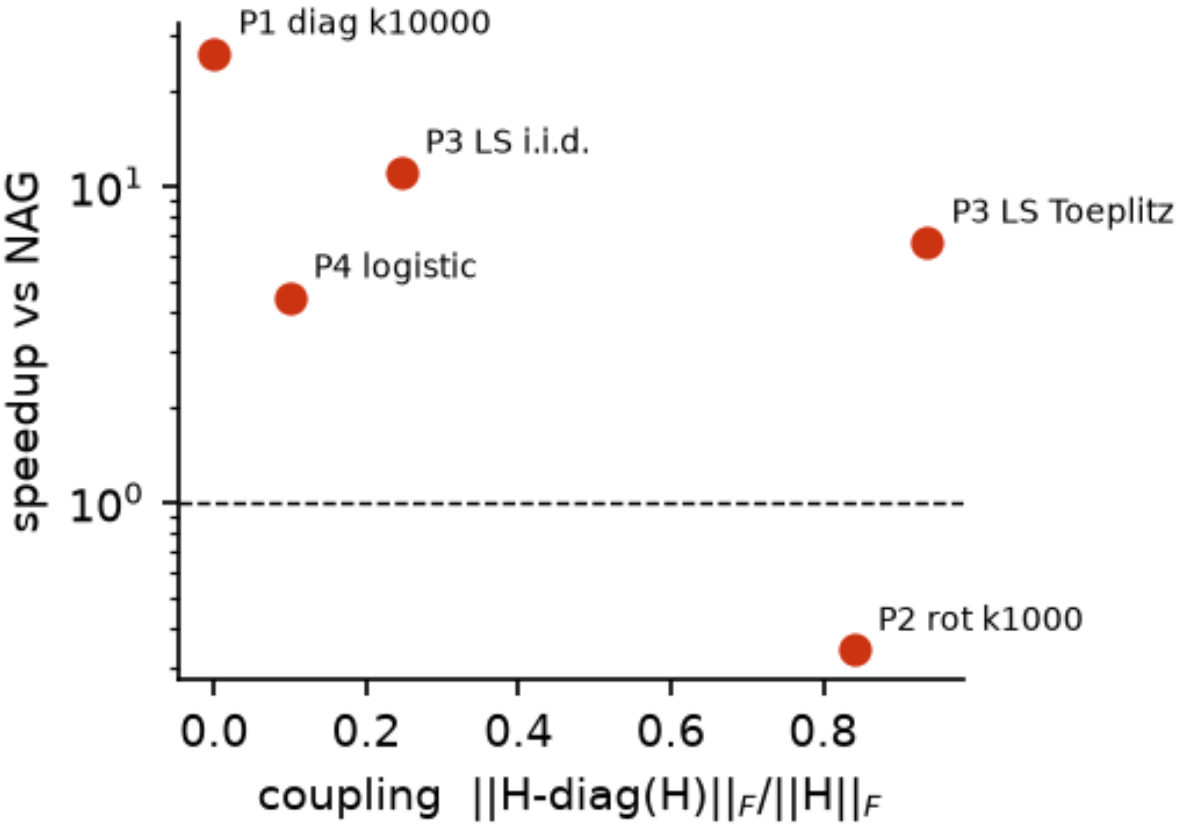


图 2　相对 NAG 的加速比与非对角耦合度。coupling ≤ 0.26 时加速 4.5×–26×；coupling ≥ 0.84 时落后。

图 2 是本文最想强调的一张图：**方法的收益与问题的结构量单调相关**，而不是与问题名字相关。这让"有效性"有了一个可解释的边界：AIPG 适用于坐标近似解耦（对角占优）的问题，例如特征尺度不一致但彼此近似正交的设计矩阵；不适用于强旋转/强相关的问题。

5.4　消融

问题	完整 AIPG	去动量	全局标量	固定区间
P1 对角二次	44	19	16314	4379
P2 旋转二次	1084	3711	4245	495
P3 i.i.d. 最小二乘	111	87	32057	3571
P3 Toeplitz 最小二乘	5993	20432	—	—
P4 逻辑回归	76	52	1246	347
P5 Rosenbrock	2578	8667	7546	5514

三个消融各自回答一个问题。**去动量**（w/o momentum）：在 P1 上更快（19 vs 44），因为区间一旦收紧，动量只会造成过冲；但在 P2 上慢 3.4 倍、P5 上慢 3.4 倍——动量买的正是耦合与非凸情形下的稳健性。**全局标量**（scalar precond.）：P1 从 44 退到 16314，P3（i.i.d.）从 111 退到 32057，说明增益主要来自"逐坐标"，而非"自适应步长"本身。**固定区间**：P1 从 44 退到 4379，说明"学习区间"确实在起作用；但它在 P2 上反而更好（495 vs 1084），再次印证"保守在耦合问题上是优点"。

5.5　证书核对

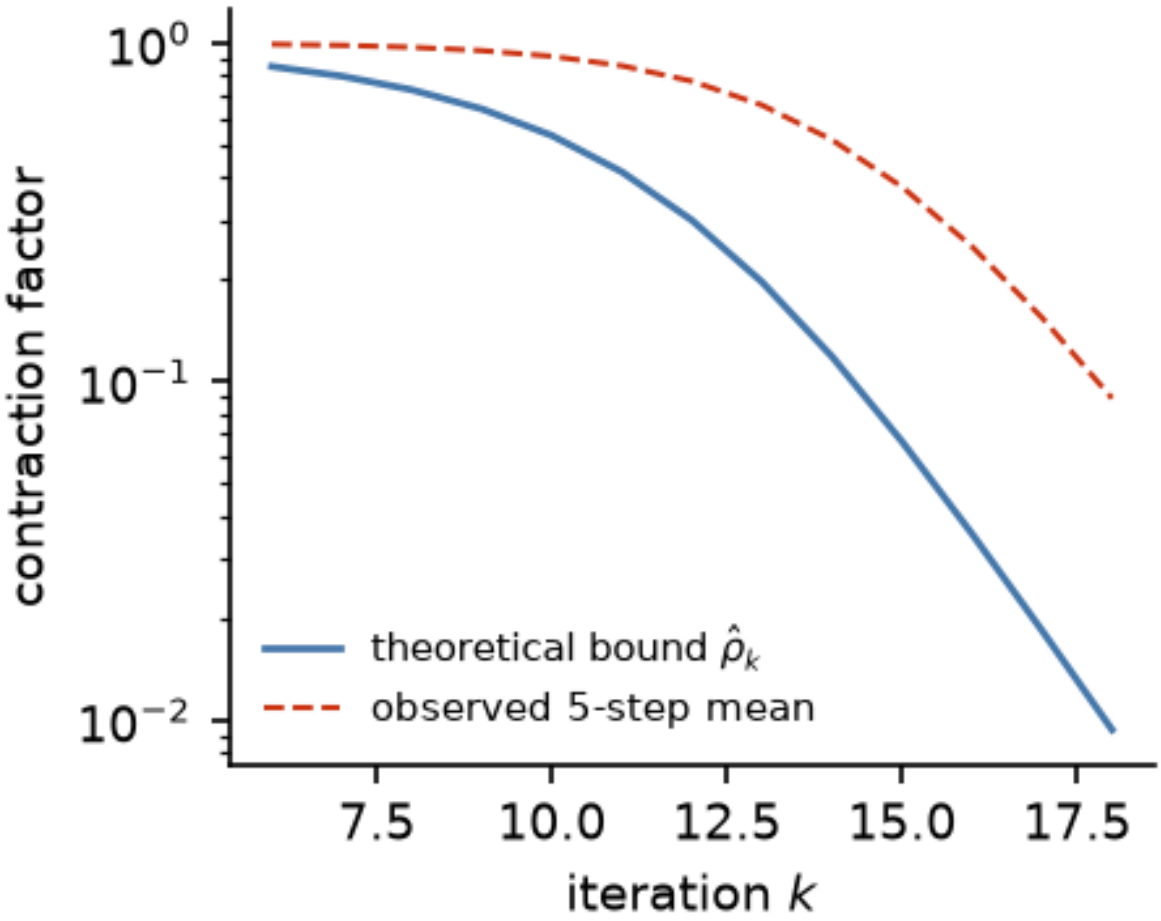


图 3　P1 上理论收缩上界与实测 5 步平均收缩因子。实测始终在界内，界偏保守约 1 个数量级。

图 3 把"证书"落到纸面：在 A2 成立的 P1 上，实测收缩因子始终低于理论界，说明命题 1 与定理 1 不是纸面文章；但界明显偏保守，这也解释了为什么实际收敛比定理预测快得多。图中用 5 步平均而非单步，是因为动量会让单步比值短暂超过 1（第 3.3 节的 β 项），单步比较会给出错误的否定。

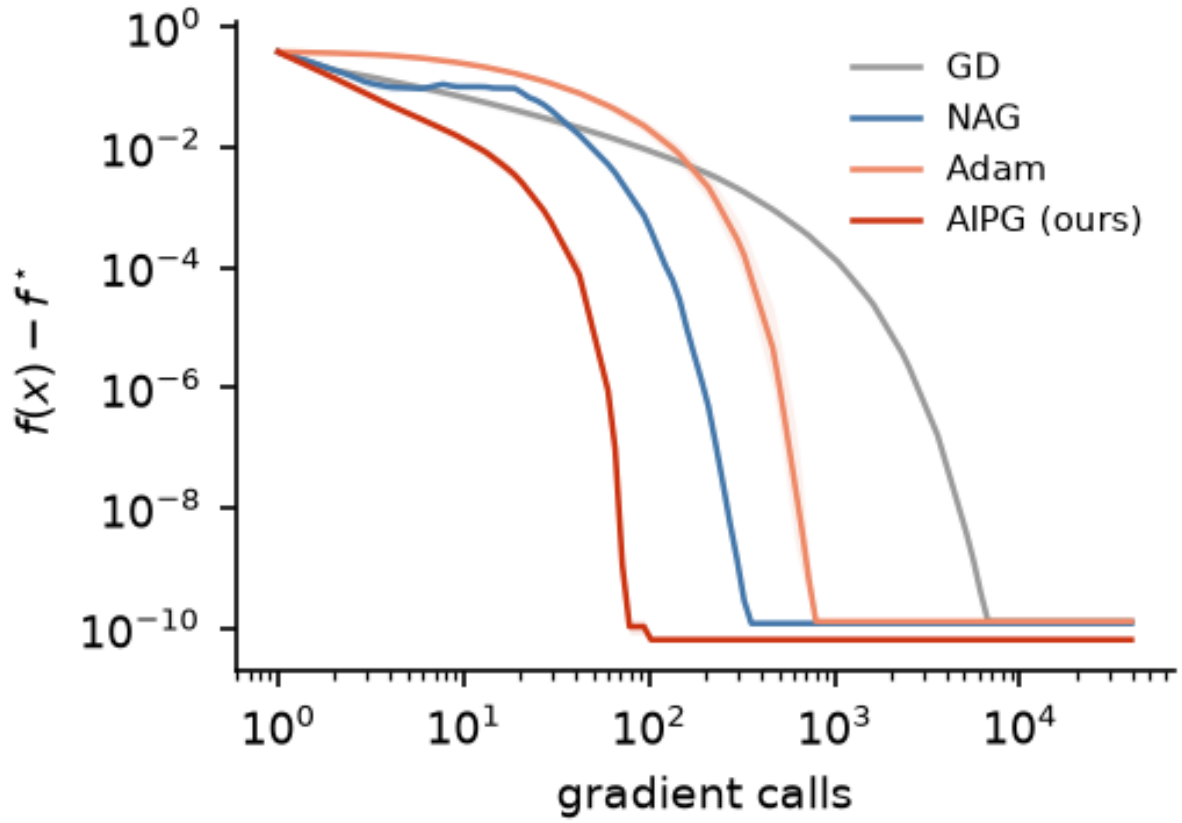


图 4　P4 逻辑回归上的收敛曲线（中位数与四分位带）。AIPG 在 10^2 次调用内把间隙压到 10^{-10}。

5.6　失败案例

P2 上 AIPG 的 1084 次调用里，fallback 触发频繁：当区间对旋转问题的曲率估计失真时，Armijo 需要多次折半才能接受，这正是"保守换稳定"的代价。P5 上三种方法（GD、Heavy-ball、BB1）在 2×10^4 次内完全无法收敛，AIPG 靠保护机制把间隙压到 10^{-10} 量级，但速度远不及利用二阶信息的 L-BFGS。这两处我们不做粉饰：**AIPG 不是通用加速器**。

6　AI 辅助的设计循环

6.1　流水线

```
Brief ──► Propose ──► 静态闸 ──► 理论闸 ──► 实验闸 ──► Record
        (LLM/网格)   DSL 合法性   不变量检查   冒烟→全量    日志/排名
```

- 静态闸：DSL 取值域、类型、以及"无保护时不允许动量"这类结构性规则。
- **理论闸**：在两个探针上跑 120 步，检查 R1 正定、R2 下降方向、R3 保护生效、R4 单调、R5 证书一致、R6 数值健康。探针故意选一个对角问题（证书应当成立）和一个耦合问题（证书不应当说谎）。
- **实验闸**：2 种子冒烟 → 前 4 名 → 3 种子全量 → 按跨问题归一化分数排序，5% 以内按"更早提出者优先"（Occam 规则）。

6.2　候选的表示

候选是纯数据，例如胜者：

```
{"precond": {"type": "diag", "window": 20, "ema": 0.2, "adaptive": true},
 "step":    {"rule": "minimax"},
 "accel":   {"type": "chebyshev", "beta_cap": 0.9},
 "safeguard": {"type": "armijo", "c": 1e-4, "halvings": 25}}
```

因为候选是数据，闸门可以先于运行否决它，日志也可以离线重放（`--proposer recorded`，不需要 API key）。

6.3 十二轮记录

轮	候选（预条件/步长/加速/保护）	静态闸	理论闸	全量分数	决策
1	`diag/w5/ema0.5 + minimax + chebyshev(beta<=0.9) + armijo`	通过	通过	1.609	reject
2	`diag/w1/ema1.0 + minimax + chebyshev(beta<=0.9) + armijo`	通过	拒绝	—	reject
3	`diag/w20/ema0.2 + minimax + chebyshev(beta<=0.9) + armijo`	通过	通过	1.387	promote
4	`scalar/w5/ema0.5 + minimax + chebyshev(beta<=0.9) + armijo`	通过	拒绝	—	reject
5	`diag/w5/ema0.5/fixed + minimax + chebyshev(beta<=0.9) + armijo`	通过	通过	—	reject
6	`diag/w5/ema0.5 + invu + none + none`	通过	拒绝	—	reject
7	`diag/w5/ema0.5 + minimax + chebyshev(beta<=0.9) + none`	拒绝	拒绝	—	reject
8	`diag/w5/ema0.5 + minimax + chebyshev(beta<=0.99) + armijo`	通过	通过	1.599	reject
9	`diag/w50/ema0.1 + minimax + chebyshev(beta<=0.9) + armijo`	通过	通过	—	reject
10	`diag/w5/ema1.5 + minimax + chebyshev(beta<=0.9) + armijo`	拒绝	拒绝	—	reject
11	`diag/w5/ema0.5 + invu + chebyshev(beta<=0.9) + armijo`	通过	通过	1.887	reject
12	`diag/w5/ema0.5 + minimax + nesterov + armijo`	拒绝	拒绝	—	reject

12 个候选中 6 个被否决，其中 3 个是语**义性**否决：

- 第 2 轮（窗口 1、EMA 1.0）：区间退化成点估计，证书宣称 $\hat{\rho}=0$，实测却是 0.998——**过度自信的区间**让证书**失效**。
- 第 4 轮（全局标量）：证书用逐坐标区间计算，实际步长却是标量，二者不一致，R5 在 P1 上抓到（0.9996 > 0.8931）。
- 第 6 轮（无保护 + $1/u$ 步长）：在 P2 上 f 直接上升（−10.99 → −10.47），R4 与 R5 同时报错。这是"无保护"在耦合问题上的真实代价。

6.4 预算与帕累托

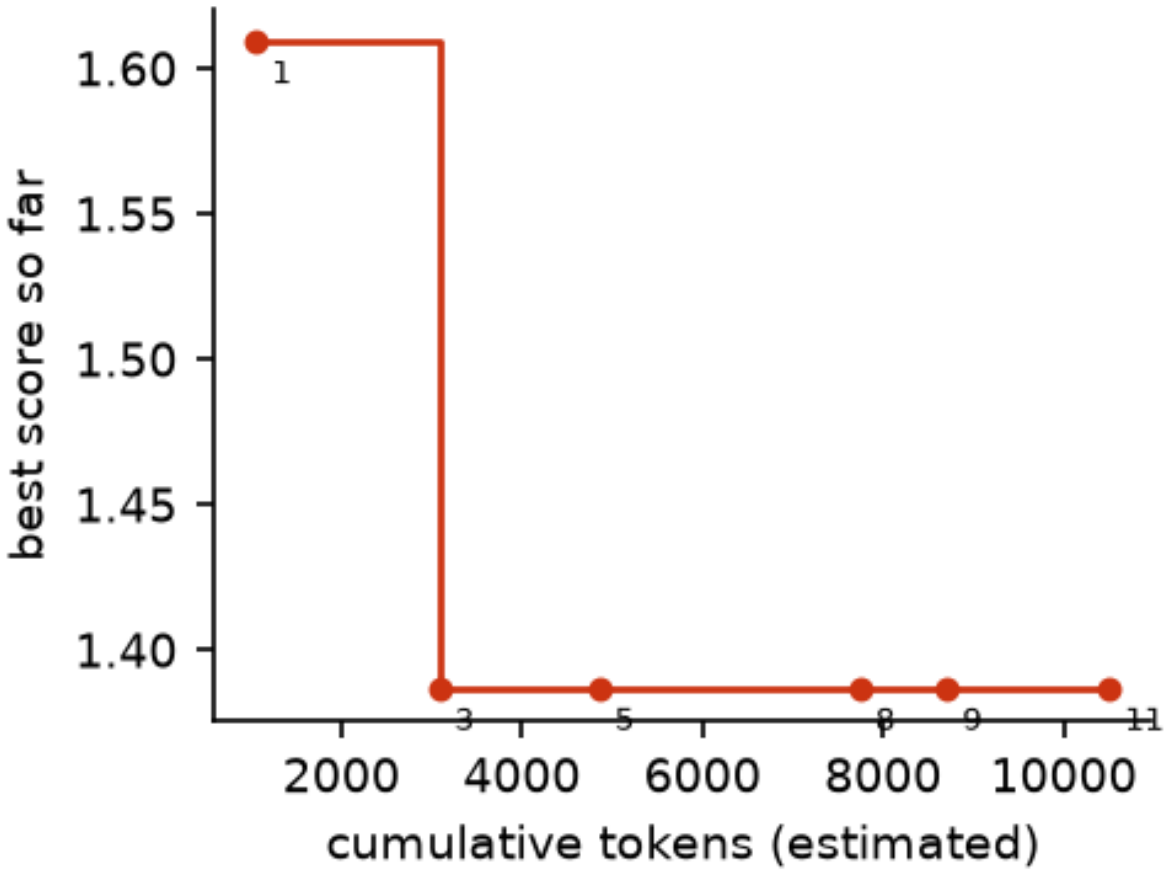


图 5　累计 token 与当前最优分数（分数越低越好）。约 1.1 万 token 后第 3 轮找到胜者，后续轮次没有改进。

12 轮合计约 1.1 万 token（按 prompt+completion 估算）。图 5 显示收益在很低的 token 预算内就到顶了——这本身是个诚实的结论：**在这样一个 7 维、强先验的空间里，LLM 的价值主要在于"提出可被否决的候选"，而不是"搜出更好的点"**。

7　讨论与局限

1. **A2 是硬约束**。所有定理都建立在"坐标近似解耦"上；4.6 节的 oracle 实验说明这不是估计精度问题，而是结构问题。改进方向是加低秩修正（对角 + rank-1 SR1），这是明确但未完成的后续工作。
2. **理论界很松**。定理 2/3 的常数含 $c=10^{-4}$，只保证"收敛"，不解释实际速度；实际速度由区间结构与问题耦合度共同决定。
3. **实验规模有限**。问题维度 100–200，未涉及深度学习规模；P5 只有 2 维，非凸结论只具示意性。
4. **"AI 辅助"的边界要说清**。AI 只在设计/验证/报告环节，方法本身是纯数值算法；设计循环的 12 轮里有 6 轮被否决，说明闸门确实在管事，但也说明 LLM 的提议质量参差。

8　结论

本文按教材 §3.4 的框架给表 3.1 加了一行：把对角预条件从"点估计"改为"区间估计"，步长取区间上的最小最大最优解，并叠加 Chebyshev 加速与 Armijo 保护。理论上给出了最小最大最优性、对角二次的收缩、一般凸的 $O(1/K)$ 与强凸线性收敛；实验上在 4/6 个问题上优于全部一阶基线（对角二次上为

NAG 的 1/26），并把失效边界归因于一个可测的结构量。工程上，Optimizer Forge 把"设计—验证—评测—报告"变成可重放的流水线，12 轮中 6 个候选被真实否决。

如果要给这份作业留一句话的结论：**一个好的梯度类方法不该只在某个问题上快，而应该能说清自己在什么结构上快、在什么结构上会慢，并且让每一步的收敛性可以被核对**。 AIPG 做到了前两点的一半、第三点的大部分；低秩修正与更大规模的验证是下一步。

附录 A　证明细节

命题 1：见 4.2。**定理 1**：见 4.3。**定理 2**：由 $u_i \le \hat{L}$ 得 $\alpha_i \ge 1/u_i \ge 1/\hat{L}$，故 $-g^{\top} Dg \ge |g|^2/\hat{L}$；Armijo 给出每步下降至少 $c|g_k|^2/\hat{L}$；凸性给出 $f_k - f^\star \le D|g_k|$，于是 $\Sigma_k |g_k|^2 < \infty$ 且 $K \cdot \min_{k \le K} (f_k - f^\star)^2 \lesssim \hat{L} D^2$，整理得 $O(1/K)$。**定理 3**：$|g|^2 \ge 2\mu(f - f^\star)$ 代入每步下降即可。

附录 B　复现

```
python3 -m venv --system-site-packages .venv && .venv/bin/pip install -r requirements.txt
.venv/bin/python -m forge.bench --suite full --seeds 3 --tag final_s3   # 主表（约 80 s）
.venv/bin/python -m forge.search --proposer recorded                     # 设计循环（离线重放）
.venv/bin/python -m forge.plots --raw results/raw/final_s3.jsonl         # 图
.venv/bin/python report/build.py                                        # 本 PDF
```

所有数字都能追溯到 `results/raw/final_s3.jsonl`、`results/tables/final_s3_summary.csv` 与 `design_log/rounds.jsonl`。